Sprawozdanie 2

Radosław Chojka

2025-06-04

Spis treści

1 Zadanie 1 **2**
1.1 Wprowadzenie 2
1.2 Modele 5
1.3 Metoda k-NN 6
1.4 Naiwny klasyfikator bayesowski 10
1.5 Drzewa klasyfikacyjne 13
1.6 Podsumowanie 21

2 Zadanie 2 **22**
2.1 Wprowadzenie 22
2.2 Porównanie klasyfikatorów złożonych 22
2.3 Metoda wektorów nośnych (SVM) 25
2.4 Porównanie skuteczności metod 32

1 Zadanie 1

1.1 Wprowadzenie

Celem analizy jest zastosowanie poznanych algorytmów klasyfikacji i szczegółowe porównanie ich dokładności. Porównanie to będzie uwzględniać następujące algorytmy:

- metoda k-najbliższych sąsiadów (*k-Nearest Neighbors*),
- drzewa klasyfikacyjne (*classification trees*),
- naiwny klasyfikator bayesowski (*naive Bayes classifier*).

Dane: **PimaIndiansDiabetes2**, biblioteka `mlbench`

- Zbiór danych PimaIndiansDiabetes2 pochodzi z badań przeprowadzonych przez *National Institute of Diabetes and Digestive and Kidney Diseases* i zawiera informacje zdrowotne dotyczące kobiet z plemienia Pima w wieku co najmniej 21 lat. Dane te zostały zebrane w celu zbadania czynników ryzyka występowania cukrzycy typu 2.
- Wersja oznaczona jako PimaIndiansDiabetes2 zawiera dodatkowo oznaczone brakujące lub niewiarygodne wartości (np. BMI równe `0` zostało zastąpione przez `NA`), co czyni ją bardziej odpowiednią do wszelkich analiz.

Rozmiar danych

```
## [1] 768   9
```

Typy poszczególnych cech:

```
## 'data.frame':    768 obs. of  9 variables:
##  $ pregnant: num  6 1 8 1 0 ...
##  $ glucose : num  148 85 183 89 137 ...
##  $ pressure: num  72 66 64 66 40 ...
##  $ triceps : num  35 29 NA 23 35 ...
##  $ insulin : num  NA NA NA 94 168 ...
##  $ mass    : num  33.6 26.6 23.3 28.1 43.1 ...
##  $ pedigree: num  0.627 0.351 ...
##  $ age     : num  50 31 32 21 33 ...
##  $ diabetes: Factor w/ 2 levels "neg","pos": 2 1 2 1 2 ...
```

- `pregnant` - Liczba przebytych ciąż
- `glucose` - Stężenie glukozy w osoczu po 2 godzinach testu doustnego (mg/dL)
- `pressure` - Ciśnienie rozkurczowe krwi (mm Hg)
- `triceps` - Grubość fałdu skórnego tricepsa (mm) – pomiar tkanki tłuszczowej
- `insulin` - Poziom insuliny w surowicy po 2 godzinach (mu U/ml)
- `mass` - Wskaźnik masy ciała (BMI): masa (kg) / [wzrost (m)]^2
- `pedigree` - Funkcja rodowodu cukrzycy – iloraz dziedziczności cukrzycy w rodzinie
- `age` - Wiek pacjentki (w latach)
- `diabetes` - Klasa diagnostyczna: `pos` oznacza występowanie cukrzycy typu 2, a `neg` brak cukrzycy (problem klasyfikacji binarnej)

Braki danych:

```
## pregnant  glucose pressure  triceps  insulin     mass pedigree      age
##        0        5       35      227      374       11        0        0
## diabetes
##        0
```

- `pregnant`, `pedigree`, `age`, `diabetes` — te zmienne są kompletne
- `glucose`, `pressure`, `mass` - mają niewielki odsetek braków (mniej niż 5% danych)
- `triceps` (227 braków, ok. 29.56%) i `insulin` (374 braków, ok. 48.7%) - mają dużo braków

Szczególną uwagę zwróciłbym na zmienną `insulin`, która z punktu widzenie medycyny może odgrywać kluczową rolę przy predykcji cukrzycy typu 2 i imputacja brakujących danych w tym przypadku będzie miała kluczowe znaczenie dla analizy.

Nie można jedynie usunąć wybrakowanych obserwacji, ponieważ stracilibyśmy większość danych.

Zastąpienie `NA` w danej cesze na średnią lub medianę z istniejących wartości w tej kolumnie utrudniłoby wiarygodną klasyfikację (model mógłby uczyć się na tych obserwacach nie istniejących lub zakłamanych wzorców).

Przeprowadzę imputację brakujących danych metodą *k-NN* (dla k = 3). Zdecydowałem się na to podejście, ponieważ dobrze sprawdza się nawet przy dużym odsetku braków, o ile pozostałe cechy są wystarczająco informatywne — co w tym przypadku ma miejsce. Mam świadomość, że zarówno wybór tej metody, jak i konkretnej wartości parametru jest nieco losowy, jednak rozwiązanie to pozwala uzyskać znacznie bardziej wiarygodne wyniki właściwej analizy niż imputacja braków średnią/medianą, czy też usuwanie obserwacji niekompletnych.

Rozkład klas:

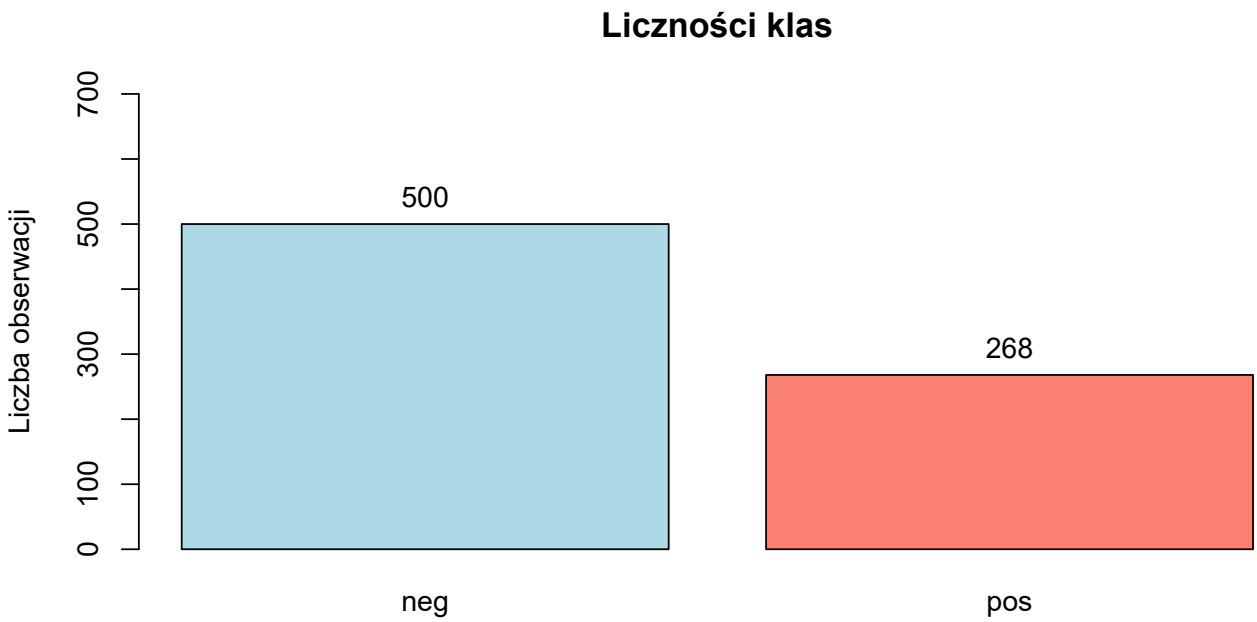

Widoczne są dysproporcje - chore pacjentki stanowią 34.9% obserwacji, natomiast zdrowe 65.1%.

Przypisując wszystkie obiekty do najczęściej występującej klasy (w tym przypadku do `neg`), uzyskalibyśmy błąd klasyfikacji 34.9%. Jest to punkt wyjścia naszej analizy, każdy stworzony przez nas klasyfikator powinien dawać niższy błąd.

Wariancje poszczególnych cech:

```
##     pregnant      glucose     pressure      triceps      insulin         mass
##   11.3540563  930.7311342  150.3937351   88.3714944 9863.1333931   47.5020090
##     pedigree          age
##    0.1097786  138.3030459
```

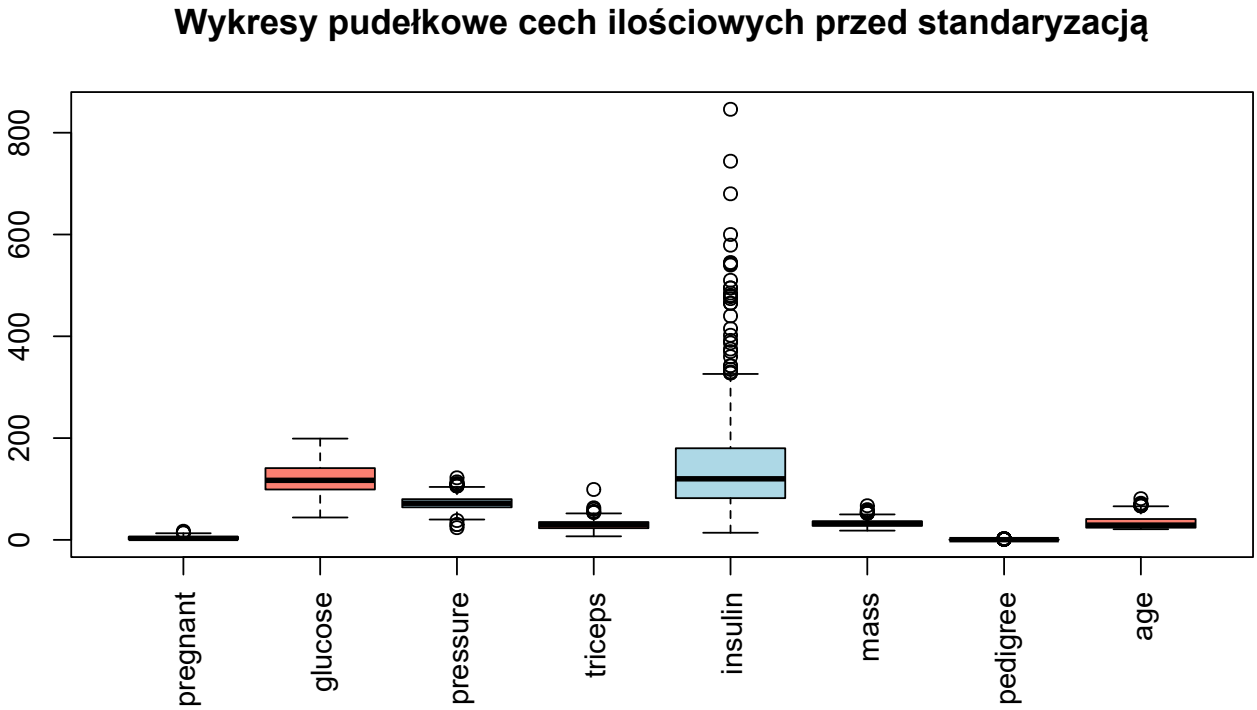

Widoczne są znaczne różnice w zmienności (wariancji) poszczególnych cech, co oznacza konieczność zastosowania standaryzacji w przypadku algorytmu *k-NN*, ponieważ cechy o większej skali mogą zdominować inne. Z kolei dane do algorytmów *drzew decyzyjnych* i *naive Bayes* nie wymagają standaryzacji – metody te są odporne na różnice w skali.

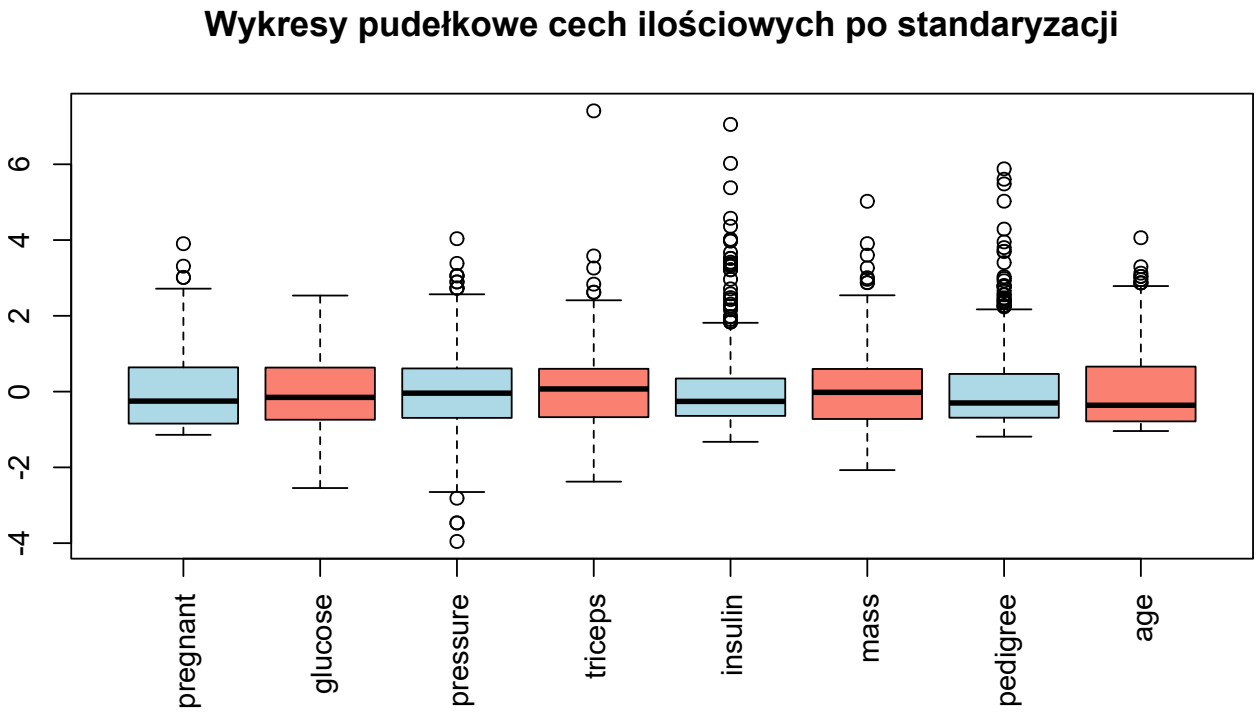

Zmienne charakteryzujące się najlepszymi zdolnościami dyskryminacyjnymi

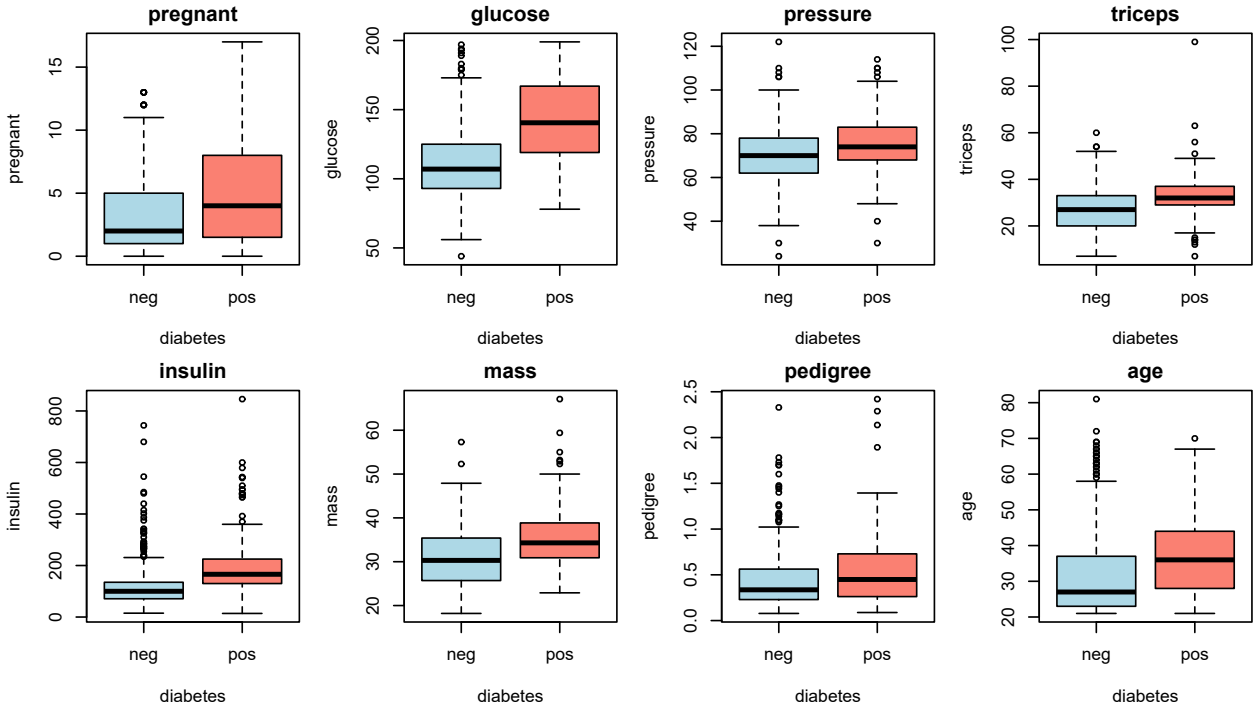

Najlepsze zmienne dyskryminacyjne:

- `glucose`: Bardzo wyraźna różnica między medianami: osoby chore mają wyraźnie wyższy poziom glukozy. Rozkłady mało nakładają się między klasami.
- `age`: Osoby chore mają zauważalnie wyższy wiek. Choć rozrzut jest szeroki, różnice między grupami są wyraźne.
- `pregnant`: Osoby chore mają większą liczbę przebytych ciąż. Mediany i kwartyle różnią się znacznie między grupami.
- `insulin`: Mediana u osób chorych jest wyższa, ale występuje duży rozrzut, wiele wartości odstających oraz niemalże połowa wartości została imputowana. Jednak ze względu na teoretyczne (z medycznego punktu widzenia) bardzo duże znaczenie tej cechy w predykcji cukrzycy, zdecydowałem się ją umieścić w tym zestawieniu (pamiętając, że wymaga ostrożnej interpretacji).

Najgorsze zmienne dyskryminacyjne:

- `pressure`, `pedigree`, `triceps` - rozkłady wartości dla grup osób zdrowych i chorych są podobne (nakładają się i mają zbliżone mediany).

1.2 Modele

W dalszej części, przy tworzeniu modeli klasyficyjnych, pisząc *Model x*, będę miał na myśli model bazujący na następujących zmiennych:

- Model 1: Wszystkie zmienne (`diabetes ~ .`)
- Model 2: Teoretycznie najlepsze zmienne (bez insuliny) (`diabetes ~ glucose + age + pregnant`)
- Model 3: Teoretycznie najlepsze zmienne (z insuliną) (`diabetes ~ glucose + insulin + age + pregnant`)
- Model 4: Teoretycznie najgorsze zmienne (`diabetes ~ pressure + pedigree + triceps`)

Oryginalny zbiór danych dzielę na zbiór uczący i zbiór testowy w sposób losowy w stosunku 2:1.

1.3 Metoda k-NN

Metoda k-NN (k-Nearest Neighbors) to nienadzorowana metoda klasyfikacji, która przypisuje nową obserwację do tej klasy, która jest najczęstsza wśród jej k najbliższych sąsiadów w przestrzeni cech. Odległość między punktami najczęściej mierzona jest za pomocą metryki euklidesowej. Metoda nie zakłada żadnych założeń co do rozkładu danych i działa dobrze przy prostych strukturach, jednak może być wrażliwa na skalę zmiennych i liczbę sąsiadów.

Macierze pomyłek dla Modelu 1.:

```
##
##
## Model: Model 1 (k = 1)
## --- Zbiór uczący ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 333   0
##          pos   0 179
##
## --- Zbiór testowy ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 139  29
##          pos  28  60
##
##
## Model: Model 1 (k = 5)
## --- Zbiór uczący ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 300  45
##          pos  33 134
##
## --- Zbiór testowy ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 147  27
##          pos  20  62
##
##
## Model: Model 1 (k = 15)
## --- Zbiór uczący ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 306  67
##          pos  27 112
##
## --- Zbiór testowy ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 144  32
##          pos  23  57
```

Uwaga!

Na podstawie wyświetlonych macierzy można zauważyć następujący trend - model częściej myli osoby chore

(pos) jako zdrowe (neg), niż zdrowe jako chore, co z punktu widzenia medycyny jest poważniejszym błędem, niż sytuacja odwrotna.

Tabela 1: Błędy klasyfikacji dla różnych modeli k-NN (%)

Model	Błąd uczący [%]	Błąd testowy [%]
Model 1 (k = 1)	0.00	22.27
Model 1 (k = 5)	15.23	18.36
Model 1 (k = 15)	18.36	21.48
Model 2 (k = 1)	0.00	30.86
Model 2 (k = 5)	16.41	24.22
Model 2 (k = 15)	25.78	24.22
Model 3 (k = 1)	0.00	21.48
Model 3 (k = 5)	15.62	21.09
Model 3 (k = 15)	22.66	19.53
Model 4 (k = 1)	0.00	39.45
Model 4 (k = 5)	22.07	34.38
Model 4 (k = 15)	28.12	33.20

Model o najniższym błędzie testowym

```
##             Model Blad_uczacy Blad_testowy
## 2 Model 1 (k = 5)       15.23        18.36
```

Wnioski:

- Dla k=1, niezależnie od kombinacji zmiennych, model nauczył się danych treningowych idealnie, zapamiętał przypadki, zamiast nauczyć się ogólnych zależności, co wskazuje na przeuczenie.
- W Modelu 4. różnica w błędzie dla zbioru uczącego i testowego jest dosyć duża, co również może świadczyć o przeuczeniu modelu.

Wpływ wyboru parametru k (liczby sąsiadów) na dokładność klasyfikacji dla rożnych podzbiorów zmiennych, przy użyciu bardziej zaawansowanych schematów oceny dokładności:

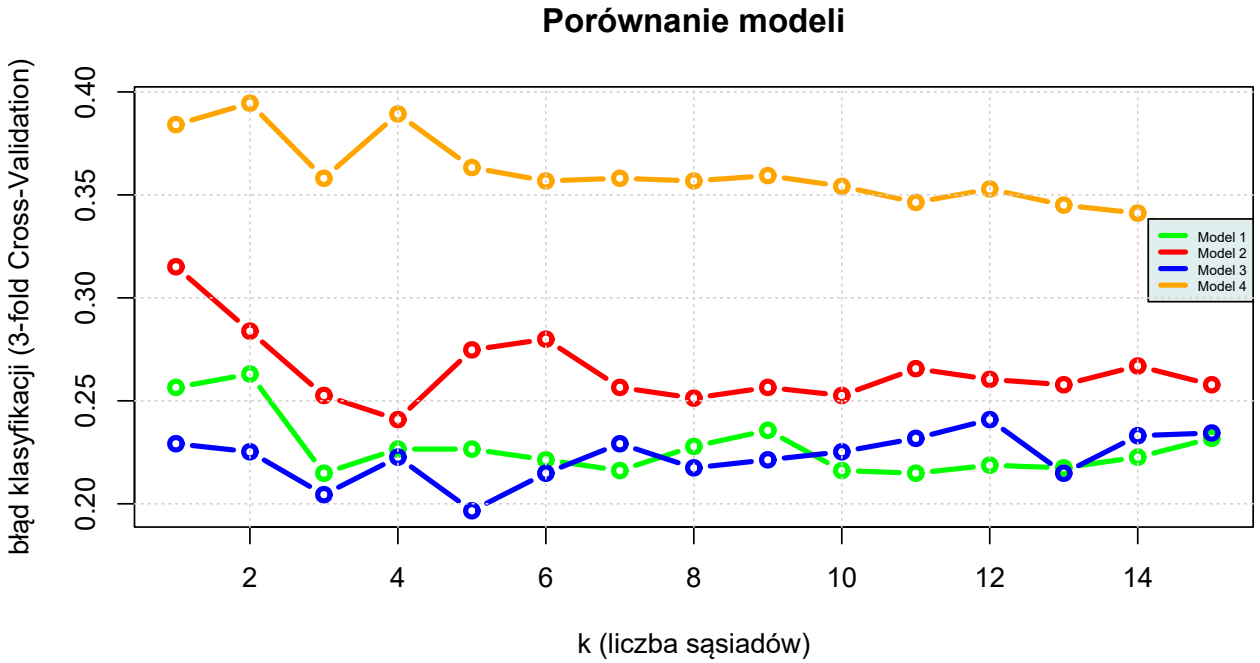

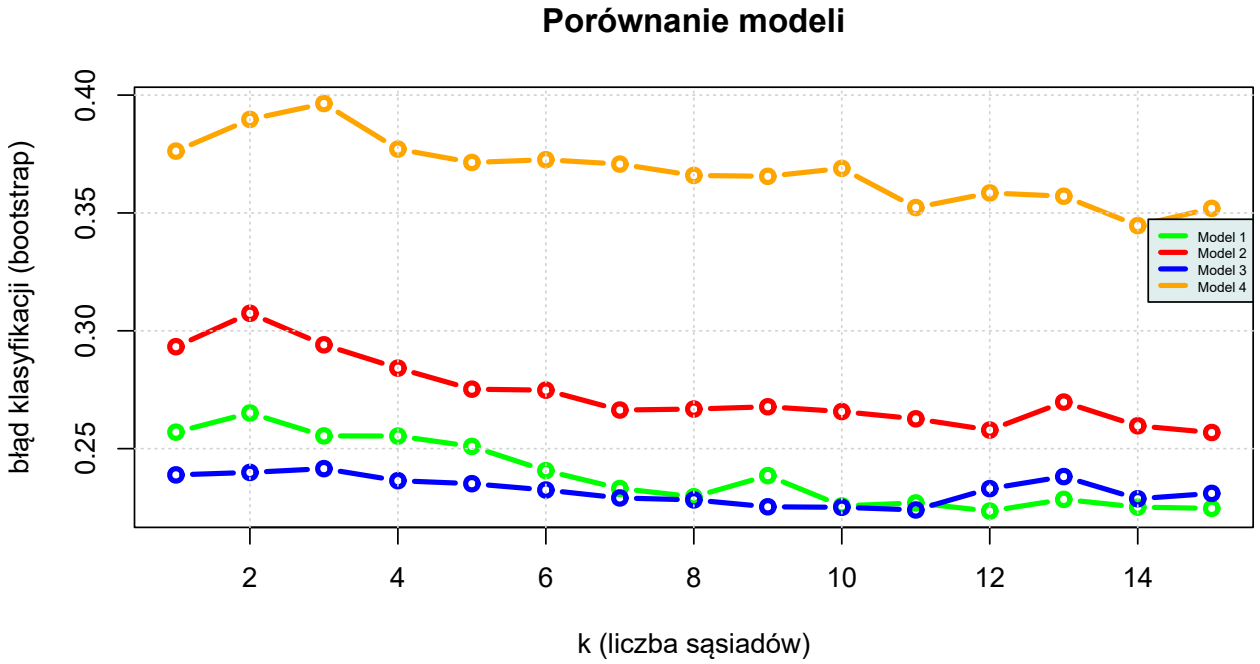

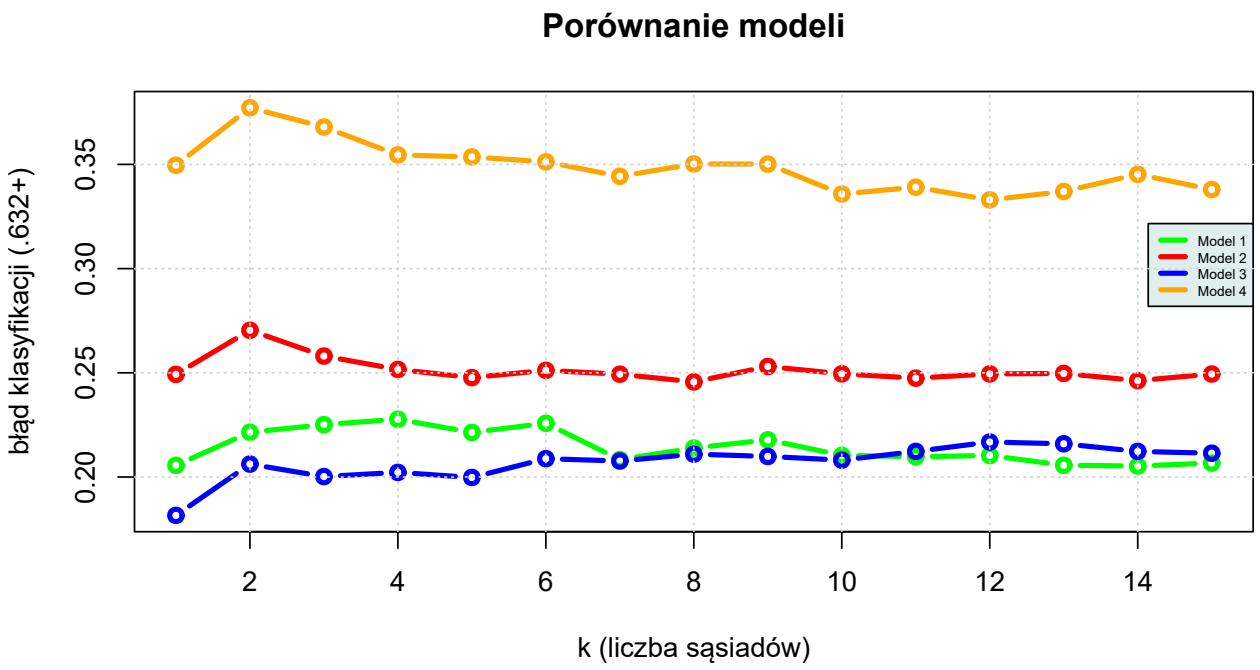

Wnioski:

- W schematach 3-fold Cross-Validation oraz bootstrap widać, że wraz ze wzrastem k (liczby sąsiadów) błąd delikatnie się zmniejsza, a w schemacie .632+ błąd oscyluje w podobnych wartościach.
- Najniższe błędy można zaobserwować dla Modelu 1. i Modelu 3. . Dla mniejszych k Model 3. wydaje się lepszy, jednak ze wzrostem liczby sąsiadów, błąd klasyfikacyjny dla Modelu 1. jest bardzo zbliżony, a nawet nieco mniejszy.
- Model 4. wypada zdecydowanie najgorzej niezależnie od parametrów i schematu oceny, co jest zgodne z oczekiwaniami.

1.4 Naiwny klasyfikator bayesowski

Naive Bayes to nadzorowana metoda klasyfikacji oparta na twierdzeniu Bayesa i założeniu naiwnej niezależności zmiennych cech – tzn. zakłada, że wszystkie cechy są od siebie niezależne warunkowo względem klasy. Model oblicza prawdopodobieństwo przynależności obserwacji do każdej klasy i przypisuje tę o najwyższym prawdopodobieństwie a posteriori.

Poniższe implementacje opierają się na założeniu niezależności zmiennych predykcyjnych – co jest podejściem *naiwnym*, ponieważ w rzeczywistości występują między nimi istotne dodatnie korelacje. Przykładowo, współczynnik korelacji między wiekiem a liczbą ciąż wynosi 0.5443412, a między poziomem glukozy i insuliny 0.591691. Takie zależności oddalają model od założenia idealnej niezależności i mogą wpływać na jego skuteczność.

- `NaiveBayes(..., usekernel = FALSE)` - dodatkowo zakłada, że warunkowe rozkłady cech są rozkładami gaussowskimi.
- `NaiveBayes(..., usekernel = TRUE)` - nie zakłada konkretnego rozkładu, zamiast tego estymuje rozkłady jądrowo.

Macierze pomyłek dla Modeli 3. i 4. (bez wykorzystania jądrowego estymatora gęstości oraz z jego użyciem):

```
## Ładowanie wymaganego pakietu: MASS
```

```
## Model: NB Model 3 (no kernel)
##
## --- Zbiór uczący ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 286  77
##          pos  47 102
##
## --- Zbiór testowy ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 140  40
##          pos  27  49
##
## Model: NB Model 3 (kernel)
##
## --- Zbiór uczący ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 278  54
##          pos  55 125
##
## --- Zbiór testowy ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 135  23
##          pos  32  66
##
## Model: NB Model 4 (no kernel)
##
## --- Zbiór uczący ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 292 123
```

```
##          pos  41  56
##
## --- Zbiór testowy ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 146  64
##          pos  21  25
##
## Model: NB Model 4 (kernel)
##
## --- Zbiór uczący ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 299 110
##          pos  34  69
##
## --- Zbiór testowy ---
##             Rzeczywiste
## Przewidziane neg pos
##          neg 144  63
##          pos  23  26
```

Tabela 2: Błędy klasyfikacji modeli Naive Bayes na zbiorze uczącym i testowym [%]

Model	Błąd uczący [%]	Błąd testowy [%]
NB Model 1 (no kernel)	22.27	25.39
NB Model 1 (kernel)	19.14	23.83
NB Model 2 (no kernel)	25.98	27.73
NB Model 2 (kernel)	23.83	25.00
NB Model 3 (no kernel)	24.22	26.17
NB Model 3 (kernel)	21.29	21.48
NB Model 4 (no kernel)	32.03	33.20
NB Model 4 (kernel)	28.12	33.59

Model o najniższym błędzie testowym

```
##                 Model Blad_uczacy_procent Blad_testowy_procent
## 6 NB Model 3 (kernel)               21.29                21.48
```

Wnioski:

- Zaróno dla zbioru uczącego jak i testowego zastosowanie jądrowej estymacji gęstości, obniża wartość błędu klasyfikacji.
- Najniższe błędy wykazują modele 1. i 3., zaś najwyższy model 4.
- Nie widać żadnego szczególnego przypadku, gdzie moglibyśmy podejrzewać przeuczenie modelu.

Bardziej zaawansowane schematy oceny dokładności

Tabela 3: Porównanie błędów klasyfikacji modeli Naive Bayes (CV, Bootstrap, .632+)

Model	Błąd CV [%]	Błąd bootstrap [%]	Błąd .632+ [%]
NB Model 1	24.09	23.79	23.71
NB Model 2	26.43	26.33	26.12
NB Model 3	24.87	25.22	24.86
NB Model 4	32.42	33.05	32.29

Wnioski:

- Przy użyciu wszystkich wymienionych powyżej zaawansowanych schematów oceny dokładności, najniższą wartość błędu wykazuje Model 1.
- Trudno jednoznacznie stwierdzić, który zaawansowany schemat oceny błędu jest najlepszy, bo w zależności od kombinacji zmiennych różne schematy wskazują najniższy błąd klasyfikacyjny.

1.5 Drzewa klasyfikacyjne

Drzewa klasyfikacyjne to popularna metoda klasyfikacji, w której dane są dzielone na podzbiory na podstawie wartości zmiennych wejściowych. Model ma strukturę drzewa, gdzie każdy węzeł odpowiada regule decyzyjnej (np. glucose > 120), a liście reprezentują klasy decyzyjne (np. "chory", "zdrowy"). Klasyfikacja nowej obserwacji polega na przejściu przez drzewo zgodnie z wartościami jej cech aż do odpowiedniego liścia. Metoda ta jest intuicyjna, łatwa do wizualizacji i dobrze radzi sobie z danymi zarówno liczbowymi, jak i kategorycznymi. Aby uniknąć przeuczenia, często stosuje się przycinanie drzewa

Model 1

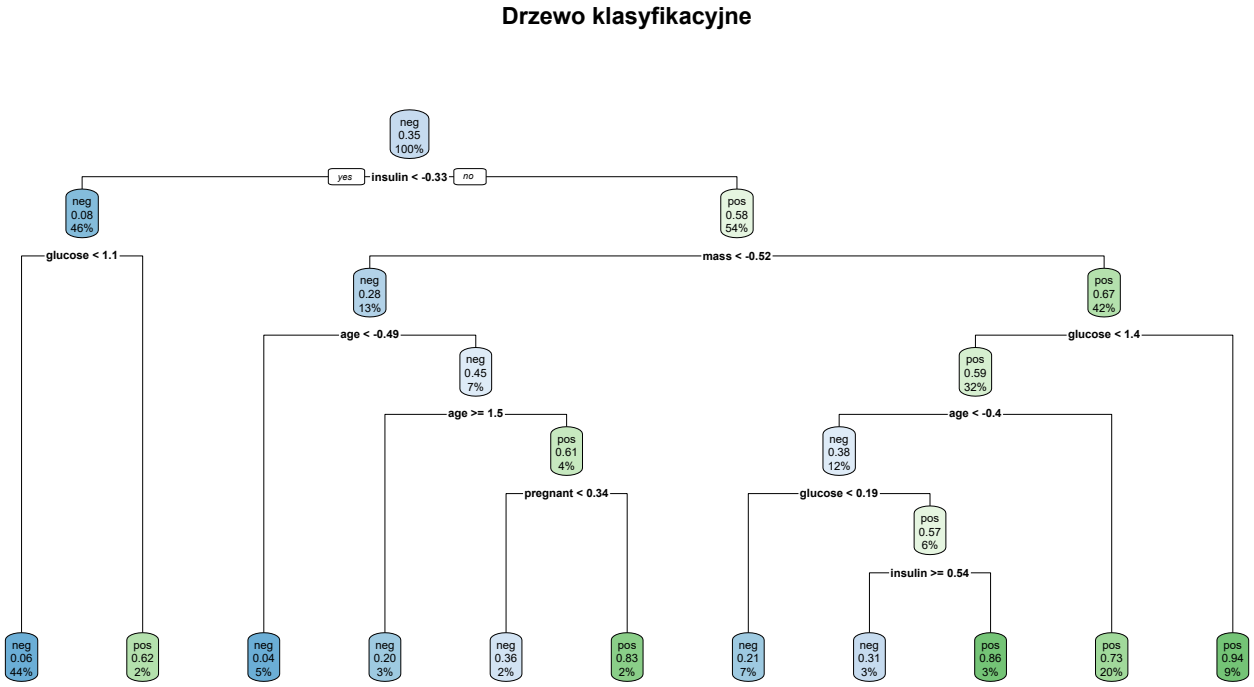

Tabela 4: Macierz pomyłek – zbiór uczący

	neg	pos
neg	295	34
pos	38	145

Tabela 5: Macierz pomyłek – zbiór testowy

	neg	pos
neg	142	26
pos	25	63

Błąd na zbiorze uczącym wynosi 14.06%, a na zbiorze testowym 19.92%.

Konstrukcja złożonego drzewa

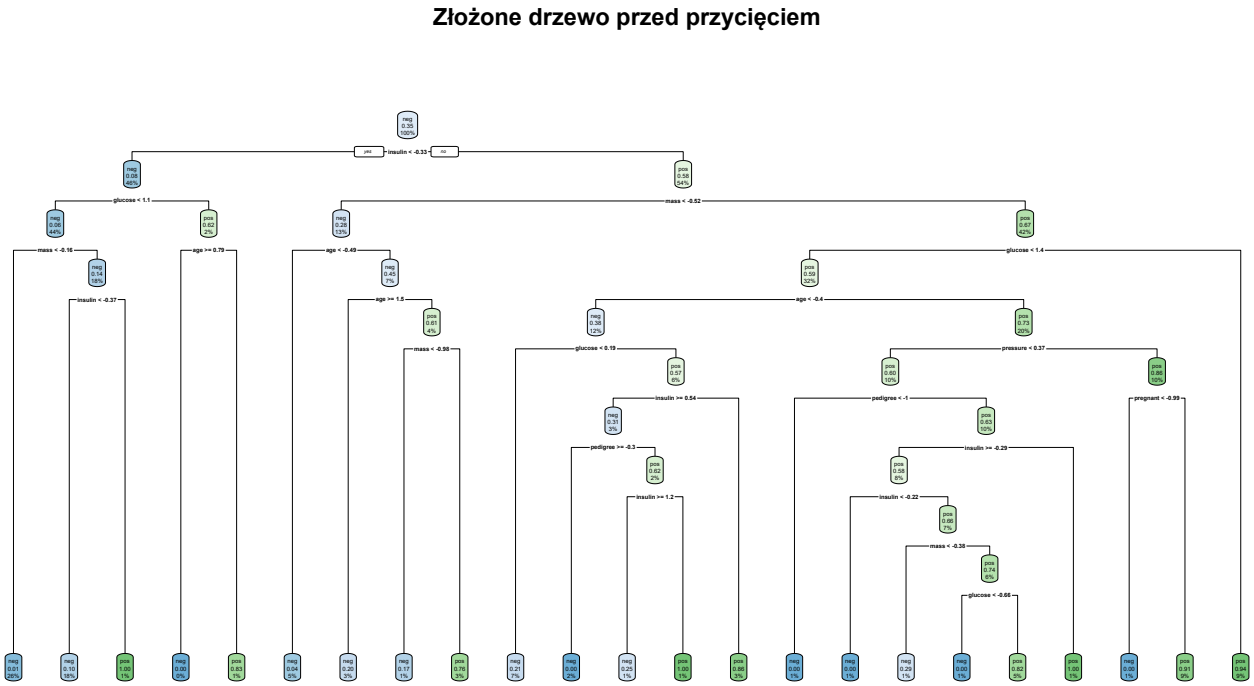

Przycinamy drzewo wg *reguły 1SE* (jednego błędu standardowego).

Idea:

- Odczytujemy najmniejszy błąd kroswalidacyjny (`xerror.min`) oraz jego odch.stand. (`xstd.min`)
- Następnie szukamy największej wartości `cp` (odpowiadającej najmniejszej złożoności modelu), dla której spełniony jest warunek: błąd kroswalidacyjny < `xerror.min` + `xstd.min`

```
##           CP nsplit rel error    xerror       xstd
## 1 0.23463687      0 1.0000000 1.0000000 0.06027825
## 2 0.16201117      1 0.7653631 0.8435754 0.05764399
## 3 0.04469274      2 0.6033520 0.7206704 0.05487901
## 4 0.02793296      4 0.5139665 0.6256983 0.05225778
## 5 0.01396648      6 0.4581006 0.5977654 0.05139624
## 6 0.01117318      9 0.4078212 0.6145251 0.05191841
## 7 0.01000000     22 0.2458101 0.6536313 0.05307665
```

Minimalny błąd kroswalidacyjny: 0.5977654 i odpowiadające mu odchylenie standardowe: 0.0513962

Największe `CP` przy `xerror` < `xerror.min` + `xstd.min`: 0.027933

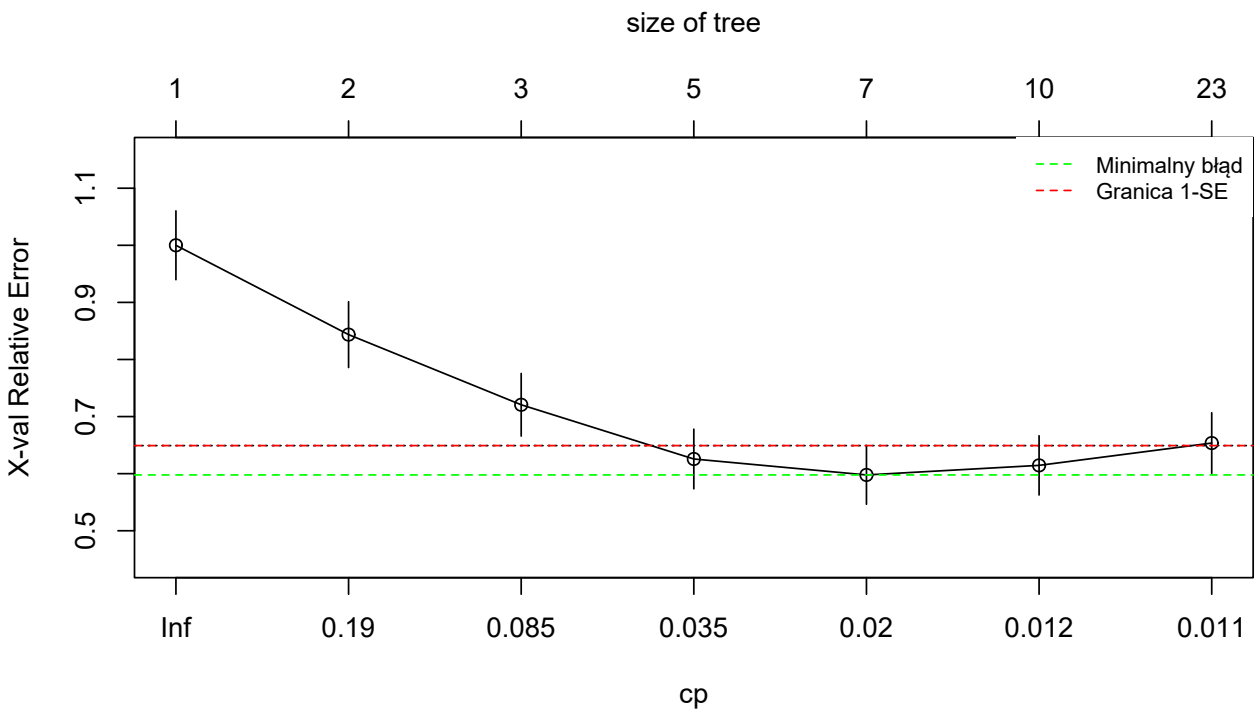

Drzewo przycięte wg zasady 1-SE

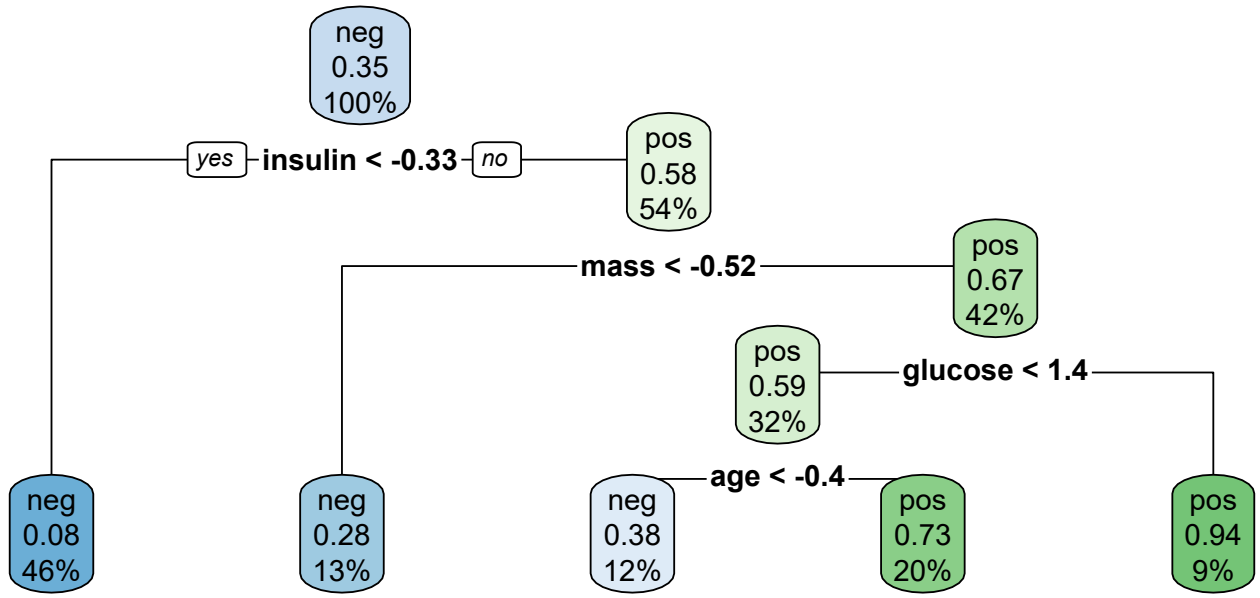

Macierze pomyłek dla złożonych drzew

Tabela 6: Macierz pomyłek (przed przycięciem) – zbiór uczący

	neg	pos
neg	314	25
pos	19	154

Tabela 7: Macierz pomyłek (przed przycięciem) – zbiór testowy

	neg	pos
neg	144	30
pos	23	59

Tabela 8: Macierz pomyłek (po przycięciu) – zbiór uczący

	neg	pos
neg	302	61
pos	31	118

Tabela 9: Macierz pomyłek (po przycięciu) – zbiór testowy

	neg	pos
neg	151	33
pos	16	56

Błąd na zbiorze uczącym przed przycięciem drzewa wynosi 8.59%, a na zbiorze testowym 20.7%, taka różnica może wskazywać na przeuczenie modelu.

Błąd na zbiorze uczącym po przycięciu drzewa wynosi 17.97%, a na zbiorze testowym 19.14%.

Przycięcie drzewa spowodowało poprawę dokładności modelu.

Model 3

Zdecydowałem się dokładniej przeanalizować również ten model, ponieważ po wynikach poprzednich analiz widać, że oprócz modelu z wszystkimi cechami, ten ma największy potencjał.

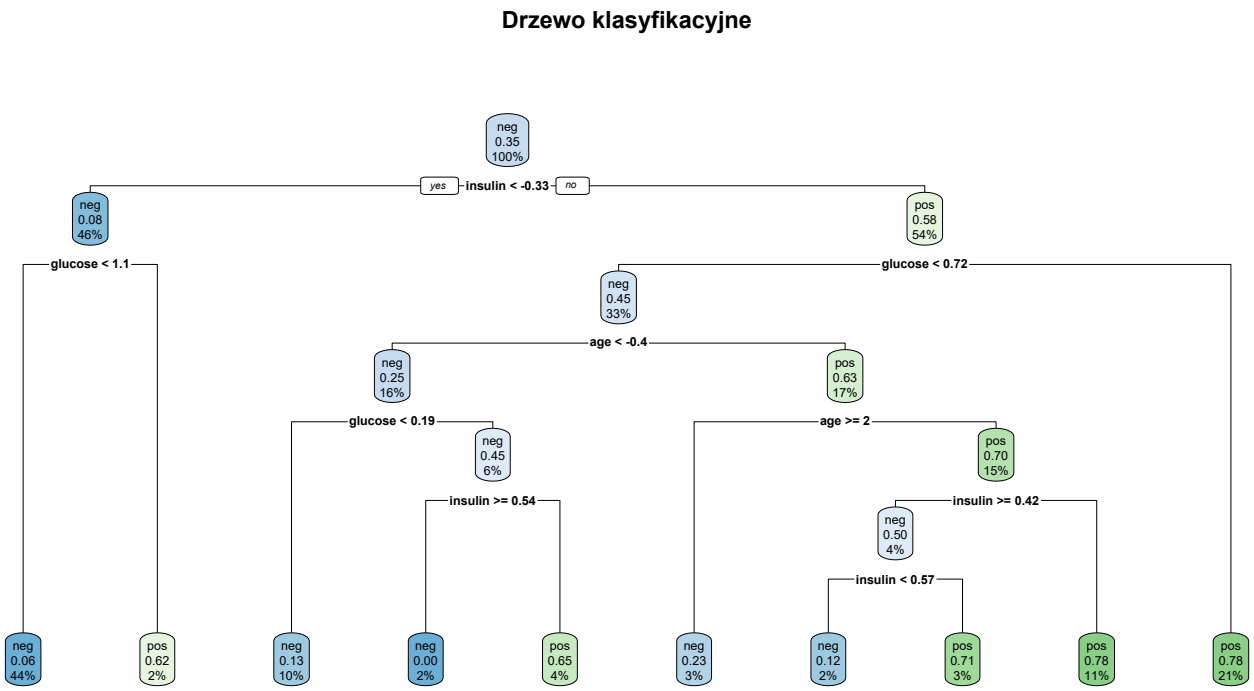

Tabela 10: Macierz pomyłek – zbiór uczący

	neg	pos
neg	283	25
pos	50	154

Tabela 11: Macierz pomyłek – zbiór testowy

	neg	pos
neg	134	14
pos	33	75

Błąd na zbiorze uczącym wynosi 14.65%, a na zbiorze testowym 18.36%.

Konstrukcja złożonego drzewa

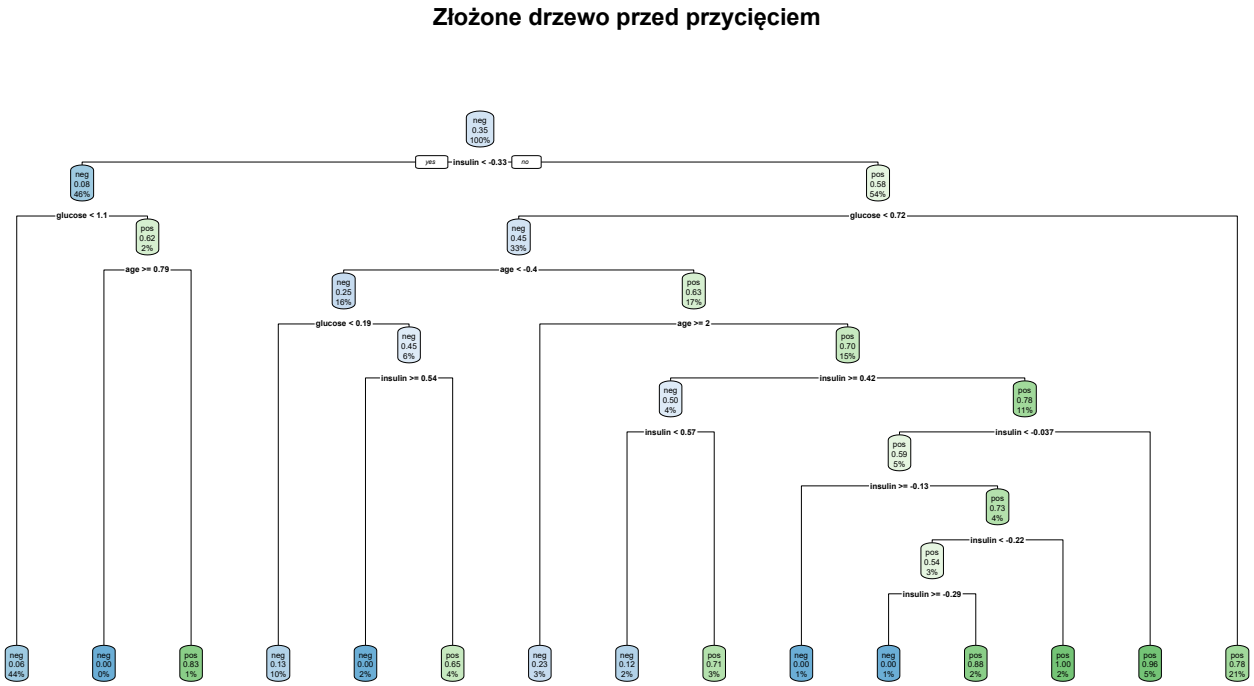

Przycinamy drzewo wg *reguły 1SE* (jednego błędu standardowego).

```
##           CP nsplit rel error    xerror       xstd
## 1 0.23463687      0 1.0000000 1.0000000 0.06027825
## 2 0.11452514      1 0.7653631 0.8044693 0.05683517
## 3 0.03910615      3 0.5363128 0.6145251 0.05191841
## 4 0.01675978      4 0.4972067 0.5977654 0.05139624
## 5 0.01396648      8 0.4301676 0.5586592 0.05011418
## 6 0.01117318     12 0.3743017 0.5586592 0.05011418
## 7 0.01000000     14 0.3519553 0.6033520 0.05157207
```

Minimalny błąd kroswalidacyjny: 0.5586592 i odpowiadające mu odchylenie standardowe: 0.0501142

Największe `CP` przy `xerror` < `xerror.min` + `xstd.min`: 0.0167598

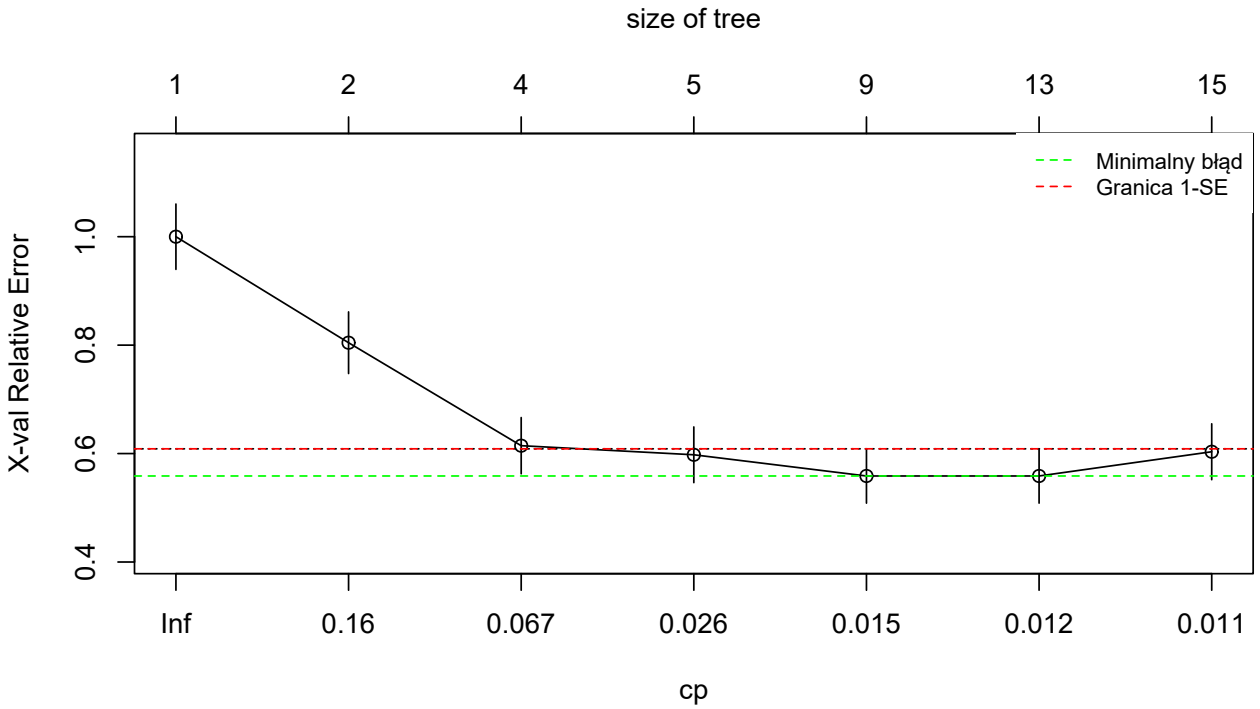

Drzewo przycięte wg zasady 1-SE

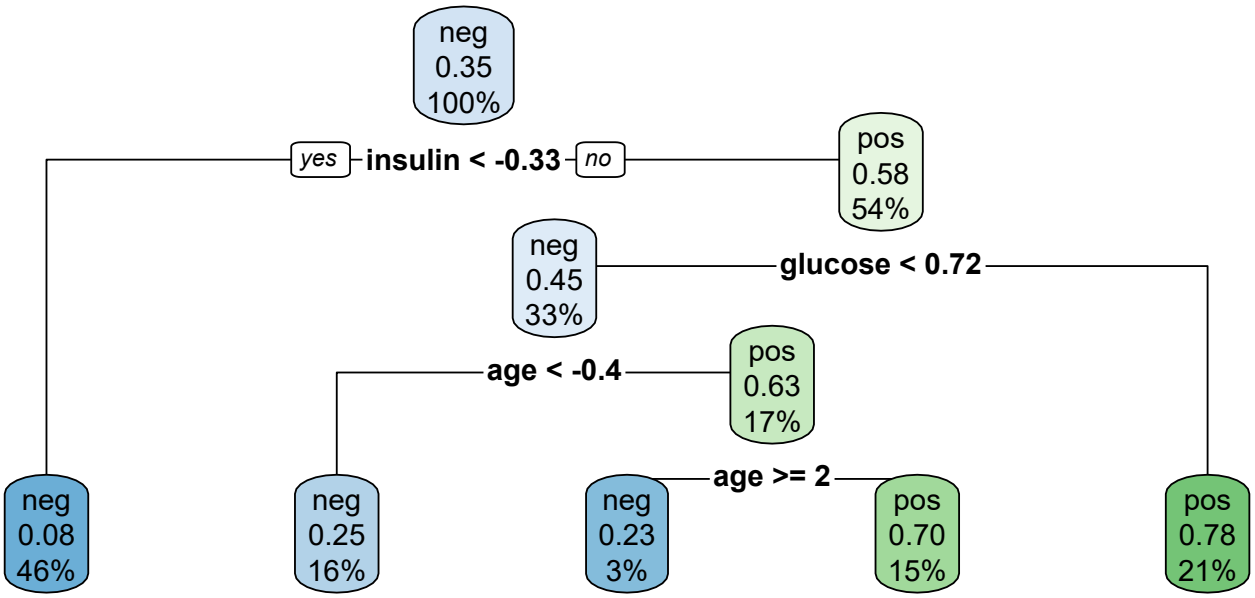

Macierze pomyłek dla złożonych drzew

Tabela 12: Macierz pomyłek (przed przycięciem) – zbiór uczący

	neg	pos
neg	295	25
pos	38	154

Tabela 13: Macierz pomyłek (przed przycięciem) – zbiór testowy

	neg	pos
neg	136	17
pos	31	72

Tabela 14: Macierz pomyłek (po przycięciu) – zbiór uczący

	neg	pos
neg	286	42
pos	47	137

Tabela 15: Macierz pomyłek (po przycięciu) – zbiór testowy

	neg	pos
neg	139	18
pos	28	71

Błąd na zbiorze uczącym przed przycięciem drzewa wynosi 12.3%, a na zbiorze testowym 18.75%, co może wskazywać na lekkie przeuczenie modelu tego drzewa.

Błąd na zbiorze uczącym po przycięciu drzewa wynosi 17.38%, a na zbiorze testowym 17.97%.

Można zauważyć delikatny wzrost błędu po przycięciu, jednak to nie musi oznaczać, że przycięcie było złe. Oznacza raczej, że model stał się bardziej ogólny, stabilniejszy, kosztem lekkiego pogorszenia dokładności.

Bardziej zaawansowane schematy oceny dokładności

Tabela 16: Porównanie błędów klasyfikacji modeli drzewa decyzyjnego (CV, Bootstrap, .632+)

Model	Błąd CV [%]	Błąd bootstrap [%]	Błąd .632+ [%]
Tree Model 1	18.62	21.89	19.01
Tree Model 2	25.52	26.28	25.42
Tree Model 3	19.14	20.81	19.83
Tree Model 4	34.11	35.18	32.64

Wnioski:

- Model 1 uzyskał najniższy błąd klasyfikacji w dwóch metodach oceny, co może sugerować, że jest to najlepszy model spośród czterech pod względem ogólnej zdolności generalizacji.
- Model 4 wykazuje zdecydowanie najwyższe błędy, co oznacza, że jest to najsłabsza kombinacja zmiennyc.
- Różnice między błędami dla każdej metody w ramach danego modelu są stosunkowo niewielkie.

1.6 Podsumowanie

- W przypadku metody k-NN i naive Bayes model częściej myli osoby chore jako zdrowe, niż zdrowe jako chore, co z punktu widzenia medycyny jest poważniejszym błędem, niż sytuacja odwrotna, która znacznie częściej występowała w macierzach pomyłek drzew klasyfikacyjnych.
- Najlepszy wynik (błąd klasyfikacyjny na zbiorze testowym = 17,97%) otrzymano dla **Modelu 3.**, czyli kombinacji cech takich jak: glukoza, insulina, wiek, liczba ciąż, metodą drzew decyzyjnych, po przycięciu złożonego drzewa.
- W przypadku analizowanych danych lepsze rezultaty, które były zbliżone do siebie (większy wpływ miał wybór zmiennych) dawały metody k-NN i drzew decyzyjnych, zaś metoda naive Bayes wykazywała praktycznie zawsze większe błędy, mogło to być spowodowane faktem, że niektore zmienne były ze sobą skorelowane np. insulina i glukoza, wiek i liczba przebytych ciąż. Więc założenie o niezależności cech było rzeczywiście w tym przypadku *naiwne*.
- Wybór schematu oceny dokładności miał istotny wpływ na końcowe wnioski dotyczące skuteczności analizowanych metod klasyfikacji. Choć zastosowane zaawansowane metody oceny – krzyżowa walidacja oraz metody bootstrapowe – dawały na ogół zbliżone do siebie wyniki, to jednak pozwalały na bardziej wiarygodną ocenę zdolności modeli do generalizacji
- Warto ponownie podkreślić kluczową rolę zmiennej insulina, a zwłaszcza jej braków w danych, które miały kluczowy wpływ na jakość wyników. Dowodem na to jest fakt, że modele trenowane na podzbiorze danych zawierającym insulinę osiągały niemal we wszystkich przypadkach lepsze rezultaty niż ich odpowiedniki bez tej zmiennej.
- Analiza wykazała, że najlepsze rezultaty uzyskano przy wykorzystaniu wszystkich dostępnych zmiennych (Model 1.) lub podzbioru: glukozy, insuliny, wieku i liczby ciąż (Model 3.). Oba podejścia dawały bardzo zbliżone wyniki, jednak w przypadku Modelu 3. imputowanie blisko 50% brakujących wartości insuliny najprawdopodobniej wprowadziło dodatkowy szum, co negatywnie wpłynęło na jego skuteczność.
- Imputowanie brakujących wartości insuliny w Modelu 1. również wprowadziło szum, jednak różnica polega na tym, że Model 1. korzysta z większej liczby zmiennych, więc negatywny wpływ imputacji mógł zostać częściowo *rozmyty* przez obecność innych silnych predyktorów. W Modelu 3., który opiera się tylko na czterech zmiennych (w tym insulina), szum pochodzący z imputacji miał większy wpływ na wyniki, ponieważ każda zmienna ma większe znaczenie dla działania modelu.

2 Zadanie 2

2.1 Wprowadzenie

Zadanie to jest kontynuacją zad. 1 i wykonujemy je dla uprzednio wybranych danych. Celem analizy jest zastosowanie (wybranych) zaawansowanych metod klasyfikacji. Porównanie to będzie uwzględniać następujące algorytmy:

- Bagging (*ensemble learning*),
- Random forest (*ensemble learning*),
- Metoda wektorów nośnych (*SVM*).

Dane: **PimaIndiansDiabetes2**, biblioteka `mlbench`

Braki danych:

Ponownie przeprowadzę imputację brakujących danych metodą *k-NN* (dla k = 3).

2.2 Porównanie klasyfikatorów złożonych

Analizę przeprowadzam dla modelu wykorzystującego wszystkie dostępne cechy. W przypadku *Random Forest*, mimo pełnego zestawu cech, każde drzewo budowane jest na losowym podzbiorze zmiennych.

2.2.1 Single tree (pojedyńcze drzewo klasyfikacyjne)

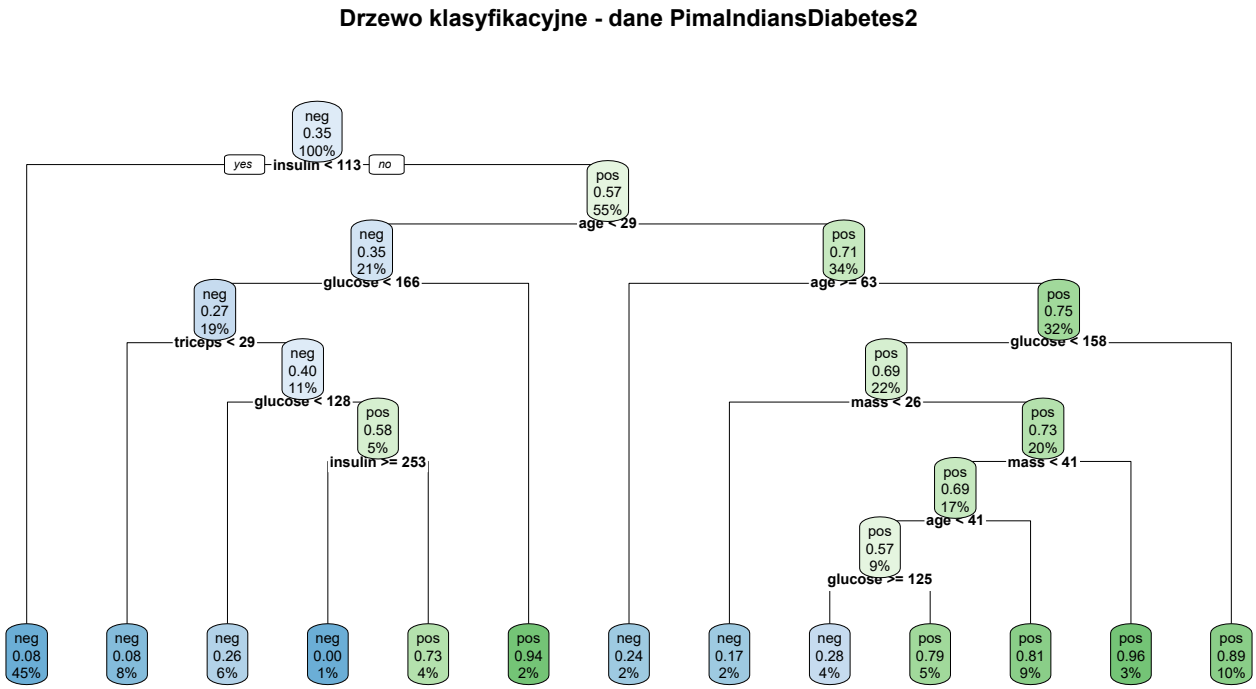

2.2.2 Bagging

Struktura:

```
## Bagging model (25 drzew):
## Liczba replikacji (nbagg): 25
## Parametry drzewa: minsplit = 1 , cp = 0
```

Jak liczba replikacji B (parametr nbagg) wpływa na dokładność modelu?

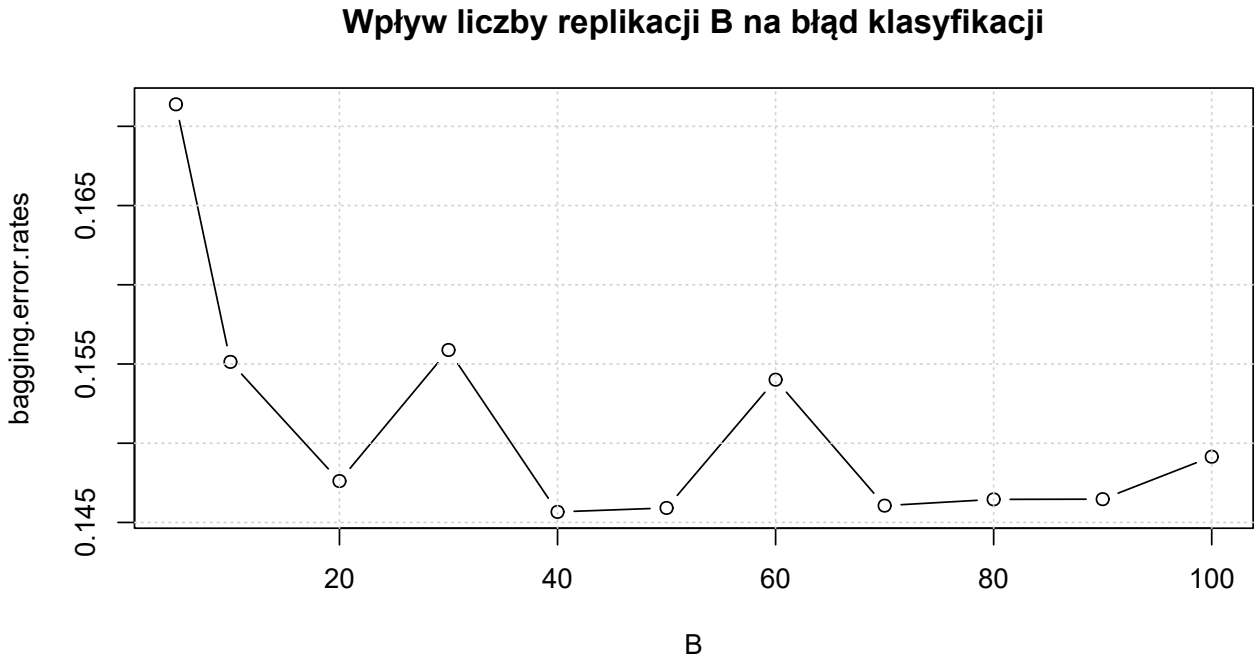

- Wzrost liczby replikacji B wpływa korzystnie na dokładność modelu – błąd klasyfikacji wyraźnie maleje przy przejściu z bardzo małych wartości B (np. 5) do wartości średnich (w zakresie 20–50). Oznacza to, że dodanie kolejnych drzew w tym przedziale znacząco poprawia jakość modelu.
- Po osiągnięciu liczby replikacji rzędu 40–50 obserwuje się stabilizację błędu – dalsze zwiększanie B nie przynosi już istotnych korzyści w zakresie dokładności.

2.2.3 Random Forest (lasy losowe)

Struktura:

```
## Liczba drzew: 100
## Liczba wybieranych losowo cech: 3
## Błąd OOB (średni): 0.1920257
```

Macierz pomyłek na bazie OOB (*Out-Of-Bag*), tzn. obserwacji, które nie były wybierane w danej replikacji

```
##     neg pos class.error
## neg 430  70   0.1400000
```

```
## pos  68 200   0.2537313
```

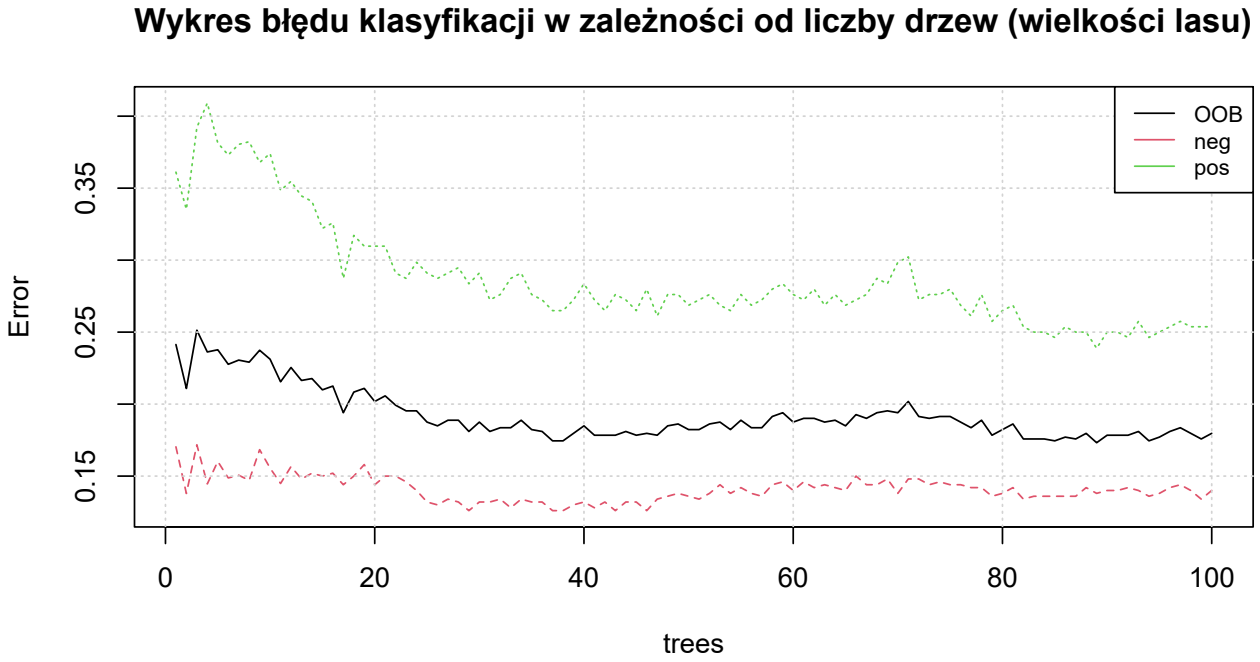

- Dodanie kilku pierwszych drzew znacząco poprawia dokładność modelu, ponieważ kolejne drzewa redukują błąd przez uśrednianie wyników.
- Po osiągnięciu określonej liczby drzew (w tym przypadku ok. 30), dalsze ich dodawanie nie przynosi już istotnej poprawy (błąd się stabilizuje).

Ranking ważności cech:

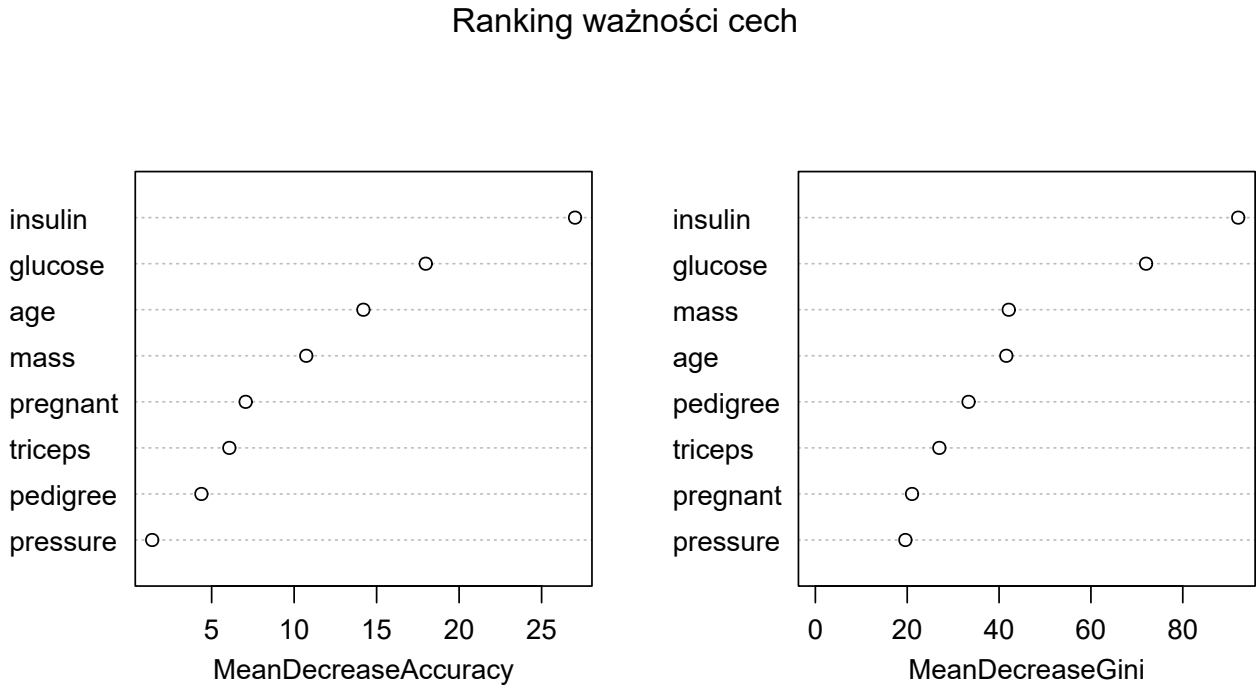

Tabela 17: Szacowany błąd klasyfikacji (.632+)

Metoda	Błąd klasyfikacji
Single Tree	0.1841
Bagging	0.1460
Random Forest	0.1346

Tabela 18: Względna redukcja błędu klasyfikacji

Porównanie	Redukcja błędu (%)
Bagging vs. Single Tree	20.71
Random Forest vs. Single Tree	26.90

Porównanie dokładności metod (metoda .632+)

- Zarówno *Bagging*, jak i *Random Forest* znacząco zmniejszają błąd klasyfikacji w porównaniu do pojedynczego drzewa.
- *Random Forest* wypadł lepiej, ponieważ wprowadza dodatkową losowość przy wyborze cech dla każdego drzewa, co zmniejsza korelacje między drzewami i pozwala lepiej wychwytywać różnorodne wzorce w danych. Dzięki temu model jest bardziej odporny na przeuczenie i lepiej generalizuje na nowych danych niż *Bagging*, który korzysta z pełnego zestawu cech.

2.3 Metoda wektorów nośnych (SVM)

Oryginalny zbiór danych dzielę na zbiór uczący i zbiór testowy w sposób losowy w stosunku 2:1. Modele tworzone są wyłącznie na podstawie dwóch zmiennych: `glucose` i `insulin`, które zostały najwyżej ocenione w rankingu ważności cech opracowanym na podstawie lasów losowych.

2.3.1 Jądro liniowe dla różnych wartości parametru kosztu

W celu porównania skuteczności klasyfikacji zastosuję trzy modele SVM z liniowym jądrem, różniące się wartością parametru kosztu C (odpowiadającego za karę za błędną klasyfikację): 0.1, 1 oraz 10.

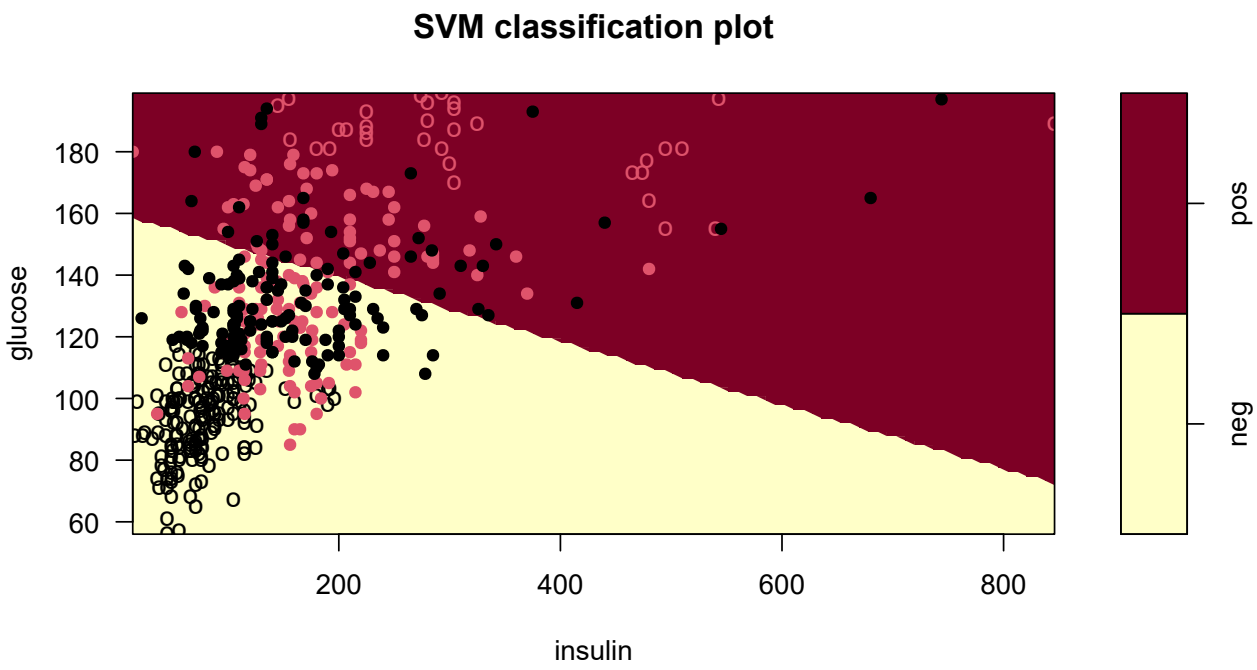

Rysunek 1: Model SVM liniowy (C = 0.1)

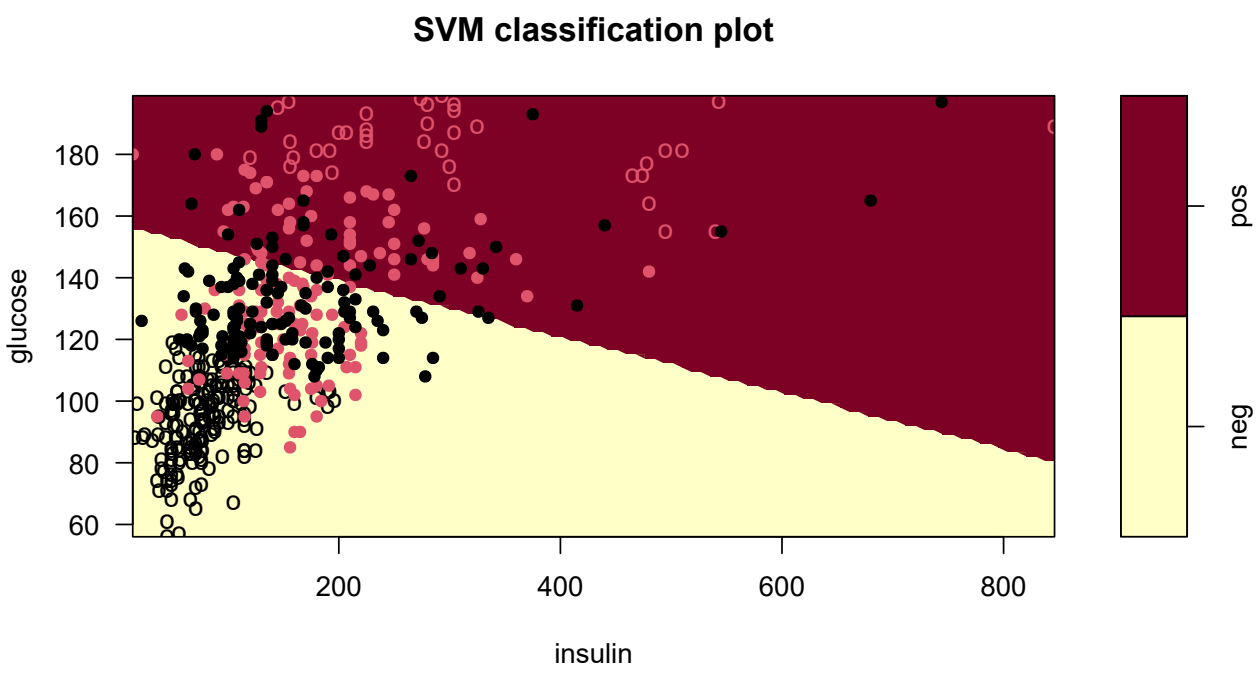

Rysunek 2: Model SVM liniowy (C = 1)

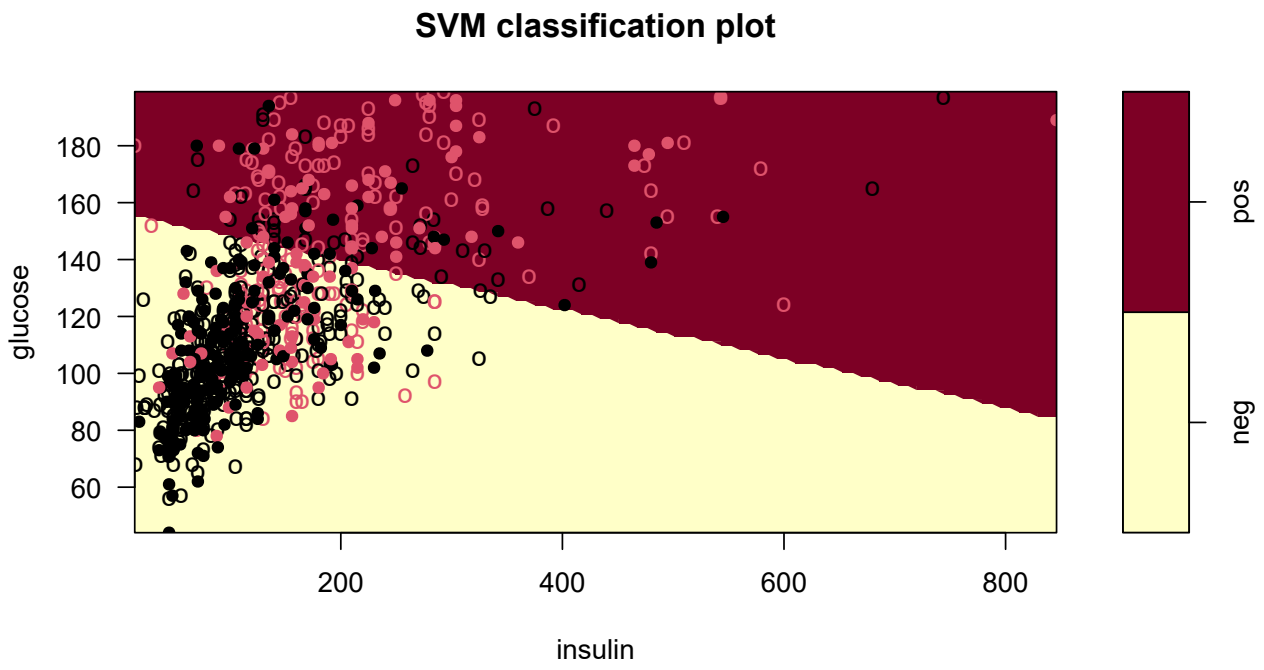

Rysunek 3: Model SVM liniowy (C = 10)

2.3.2 Porównanie wyników dla różnych funkcji jądrowych

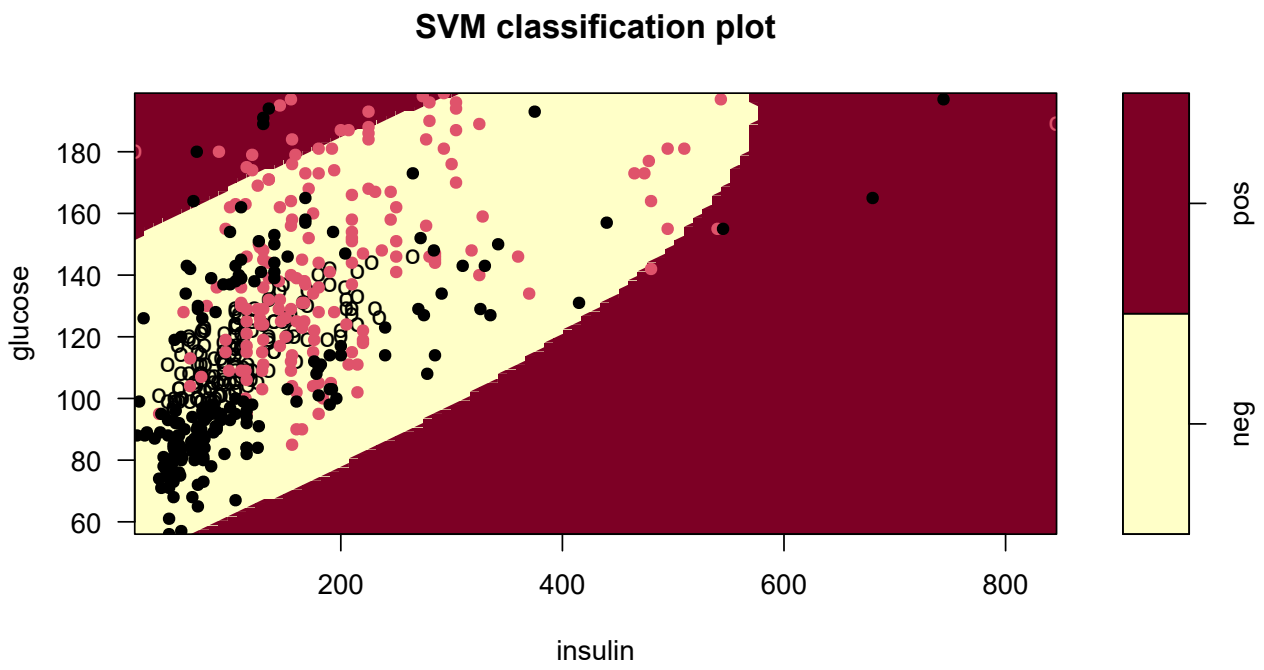

Rysunek 4: Jądro wielomianowe (stopień 2)

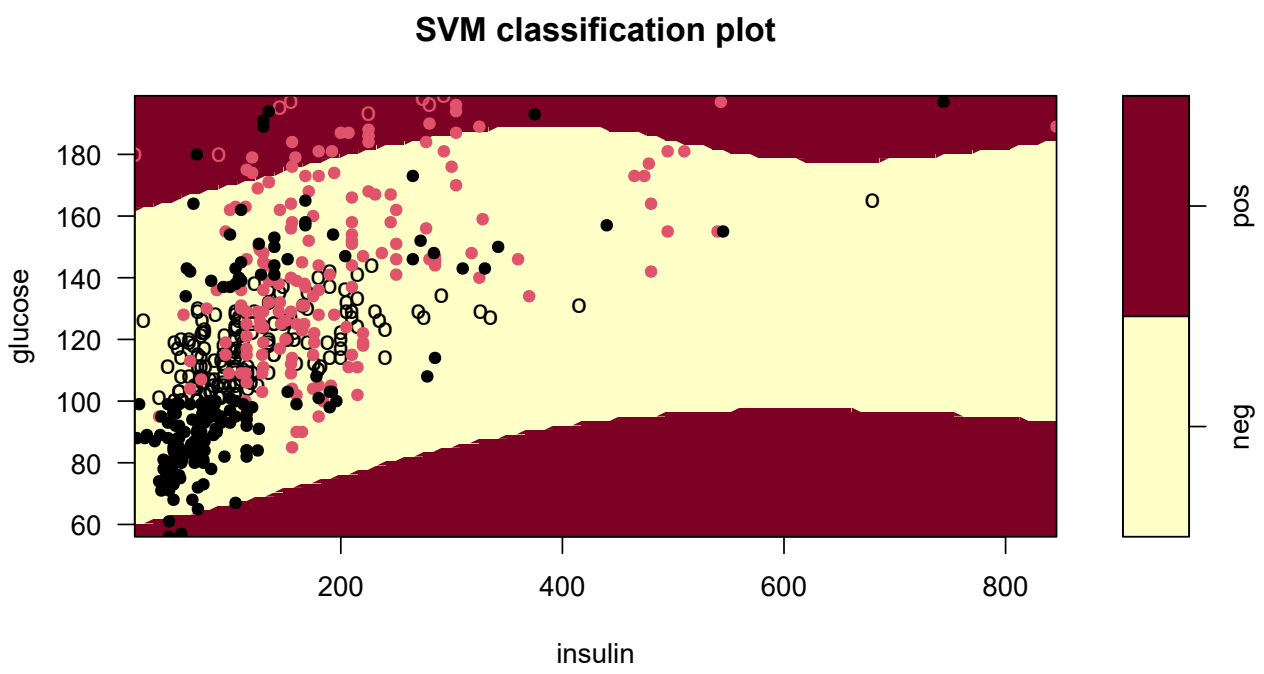

Rysunek 5: Jądro wielomianowe (stopień 4)

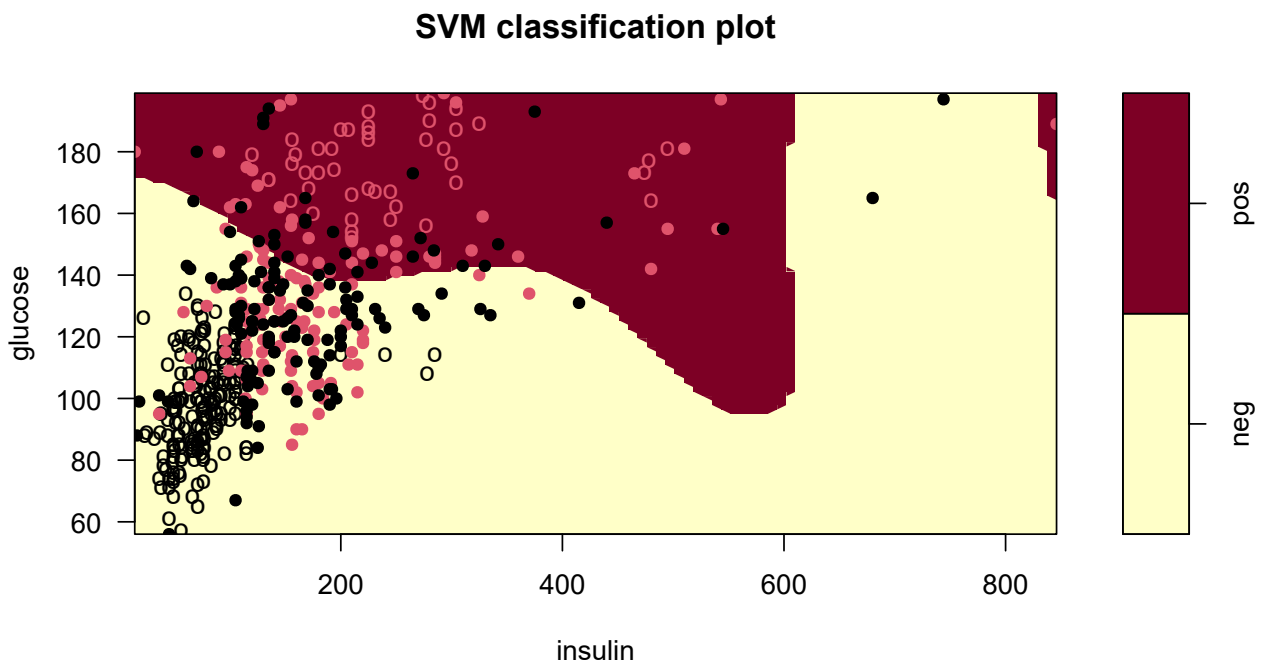

Rysunek 6: Jądro radialne (gamma = 0.5)

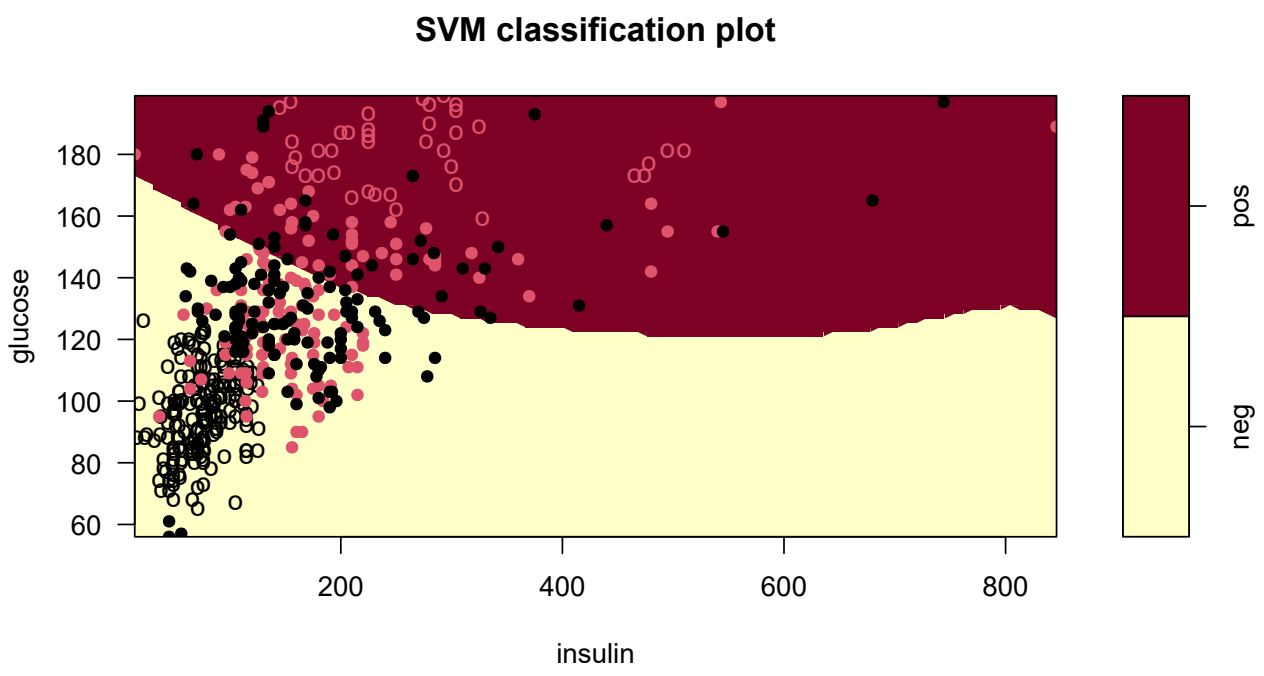

Rysunek 7: Jądro radialne (gamma = 0.1)

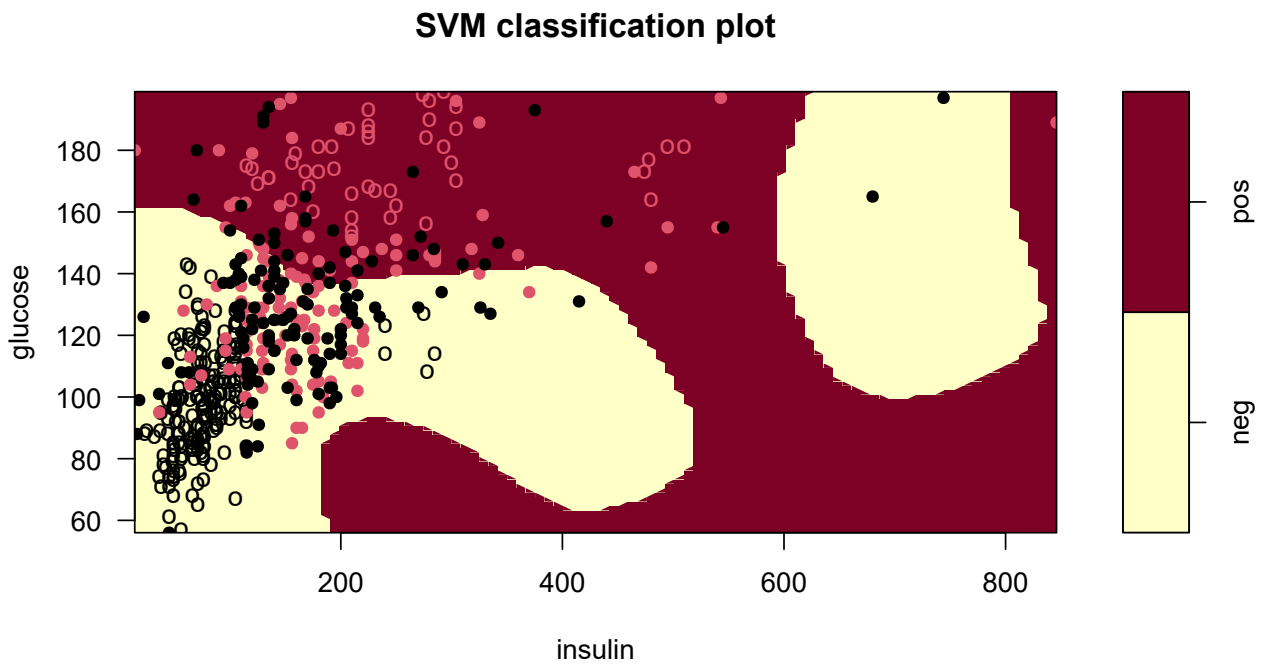

Rysunek 8: Jądro radialne (gamma = 1)

Porównanie dokładności:

Tabela 19: Porównanie błędu klasyfikacji modeli SVM z różnymi funkcjami jądrowymi i parametrami

Funkcja jądrowa / parametr	Błąd klasyfikacji
Liniowa (C = 0.1)	0.2891
Liniowa (C = 1)	0.2852
Liniowa (C = 10)	0.2891
Wielomianowa (stopień 2)	0.3398
Wielomianowa (stopień 4)	0.3359
RBF (gamma = 0.5)	0.2812
RBF (gamma = 0.1)	0.2891
RBF (gamma = 1)	0.2773

- W przypadku jąder liniowych zmiana parametru C nie prowadzi do istotnych różnic w błędzie klasyfikacji – wszystkie wyniki są bardzo zbliżone.
- Wybór stopnia wielomianu w funkcji jądrowej nie wpłynął znacząco na wynik — zarówno dla stopnia 2, jak i 4 błąd klasyfikacji pozostał na zbliżonym poziomie, jednak warto podkreślić, że ten rodzaj jądra wypadł zdecydowanie najgorzej.
- Z kolei dla funkcji z jądrem radialnym obserwujemy większe zróżnicowanie wyników. Dla gamma = 1 uzyskaliśmy najlepszy wynik.

2.3.3 Jądro gaussowskie (optymalizujemy C i gamma)

Najlepsze parametry i najniższy błąd na zbiorze uczącym:

```
##
## Parameter tuning of 'svm':
##
## - sampling method: 10-fold cross validation
##
## - best parameters:
##  cost      gamma
##     2 0.00390625
##
## - best performance: 0.2402715
```

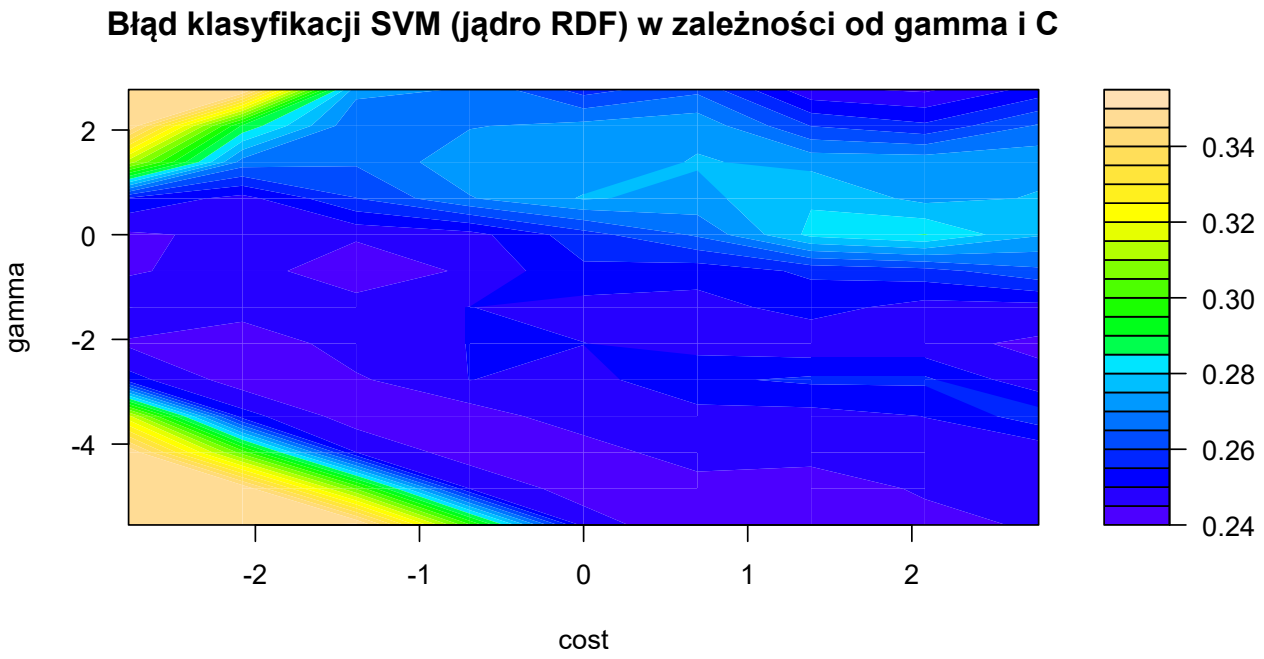

Dopasowujemy końcowy model dla optymalnych parametrów

```
## Kernel: 2
## Liczba wektorów nośnych: 320
## Liczba klas: 2
## Poziomy klas: neg, pos
## Parametry jądra:
##   - cost (C): 2
##   - gamma: 0.00390625
```

Tabela 20: Porównanie błędu klasyfikacji na zbiorze testowym: SVM radialne (przed i po tuningu)

Model	Błąd klasyfikacji
SVM radialne (domyślne parametry)	0.2812
SVM radialne (po tuningu)	0.2695

- Optymalizacja parametrów pozwoliła na poprawę skuteczności skonstruowanego klasyfikatora

2.4 Porównanie skuteczności metod

Tabela 21: Porównanie błędów klasyfikacyjnych różnych metod

Metoda	Błąd klasyfikacyjny
SVM Wielomian st. 2	0.340
SVM Wielomian st. 4	0.336
SVM Radial tuned	0.270
SVM Radial, gamma = 0.5	0.281
SVM Radial, gamma = 0.1	0.289
SVM Radial, gamma = 1	0.277
SVM Liniowy, C=0.1	0.289
SVM Liniowy, C=1	0.285
SVM Liniowy, C=10	0.289
Bagging, nbagg=25	0.146
Random Forest, ntree=100	0.135

Wniosek:

Metody zespołowe (*Bagging* oraz *Random Forest*) zdecydowanie przewyższają skutecznością pojedyncze metody SVM na tym zbiorze danych. Najlepszym modelem okazał się *Random Forest*, który osiągnął najniższy błąd klasyfikacyjny i tym samym najlepszą zdolność do generalizacji.