Sprawozdanie 1

Radosław Chojka

2025-04-30

Spis treści

1 Zadanie 1 **1**
1.1 Wprowadzenie 1
1.2 Własności poszczególnych cech 1
1.3 Porównanie nienadzorowanych metod dyskretyzacji 4

2 Zadanie 2 **10**
2.1 Wprowadzenie 10
2.2 Analiza składowych głównych (PCA) 12
2.3 Wizualizacja danych wielowymiarowych 19
2.4 Korelacja zmiennych 22
2.5 Końcowe wnioski 24

1 Zadanie 1

1.1 Wprowadzenie

Wykorzystujemy zbiór danych zawierający wyniki pomiarów uzyskanych dla trzech gatunków irysów (tj. `setosa`, `versicolor` i `virginica`), który został udostępniony przez Ronalda Fishera w roku 1936. Pomiary dotyczą długości oraz szerokości dwóch różnych części kwiatu– działki kielicha (ang. sepal) oraz płatka (ang. petal).

Rozmiar danych:

Ramka ma 150 wierszy i 5 kolumn.

Typy poszczególnych cech:

```
## 'data.frame':    150 obs. of  5 variables:
##  $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
##  $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
##  $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
##  $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
##  $ Species     : Factor w/ 3 levels "setosa","versicolor",..: 1 1 1 1 1 1 1 1 1 1 ...
```

- Widać, że zbiór danych zawiera 4 zmienne typu ilościowego (`num`), opisujące :
  - `Sepal.Length` - długość działki kielicha
  - `Sepal.Width` - szerokość działki kielicha
  - `Petal.Length` - długość płatka
  - `Petal.Width` - szerokość płatka

oraz jedną zmienną typu jakościowego (`Factor`) - `Species` - opisującą do jakiego gatunku irysu (tj. `setosa`, `versicolor` i `virginica`) należy badany kwiat.

1.2 Własności poszczególnych cech

- Aby ocenić, która spośród cech (`Sepal.Length`, `Sepal.Width`, `Petal.Length`, `Petal.Width`) pozwala najlepiej rozróżnić od siebie trzy gatunki irysa, zostanie przeprowadzona analiza opisowa. Będzie ona polegała na:
  - obliczeniu podstawowych wskaźników sumarycznych dla każdej z tych cech (`Sepal.Length`, `Sepal.Width`, `Petal.Length`, `Petal.Width`), uwzględniając podział na gatunki irysa (tj. `setosa`, `versicolor` i `virginica`),
  - utworzeniu wykresów dla tych cech, uwzględniając podział na gatunki irysa (tj. `setosa`, `versicolor` i `virginica`).

Tabele wskaźników sumarycznych:

Tabela 1: Podstawowe wskaźniki sumaryczne dla zmiennnych `Sepal.Length, Sepal.Width, Petal.Length, Petal.Width` - gatunek `setosa`

	min	Q1	median	mean	Q3	max	var	sd	IQR
Sepal.Length	4.3	4.8	5.0	5.01	5.20	5.8	0.12	0.35	0.40
Sepal.Width	2.3	3.2	3.4	3.43	3.68	4.4	0.14	0.38	0.48
Petal.Length	1.0	1.4	1.5	1.46	1.58	1.9	0.03	0.17	0.18
Petal.Width	0.1	0.2	0.2	0.25	0.30	0.6	0.01	0.11	0.10

Tabela 2: Podstawowe wskaźniki sumaryczne dla zmiennnych `Sepal.Length, Sepal.Width, Petal.Length, Petal.Width` - gatunek `versicolor`

	min	Q1	median	mean	Q3	max	var	sd	IQR
Sepal.Length	4.9	5.60	5.90	5.94	6.3	7.0	0.27	0.52	0.70
Sepal.Width	2.0	2.52	2.80	2.77	3.0	3.4	0.10	0.31	0.48
Petal.Length	3.0	4.00	4.35	4.26	4.6	5.1	0.22	0.47	0.60
Petal.Width	1.0	1.20	1.30	1.33	1.5	1.8	0.04	0.20	0.30

Tabela 3: Podstawowe wskaźniki sumaryczne dla zmiennnych `Sepal.Length, Sepal.Width, Petal.Length, Petal.Width` - gatunek `virginica`

	min	Q1	median	mean	Q3	max	var	sd	IQR
Sepal.Length	4.9	6.23	6.50	6.59	6.90	7.9	0.40	0.64	0.67
Sepal.Width	2.2	2.80	3.00	2.97	3.18	3.8	0.10	0.32	0.38
Petal.Length	4.5	5.10	5.55	5.55	5.88	6.9	0.30	0.55	0.78
Petal.Width	1.4	1.80	2.00	2.03	2.30	2.5	0.08	0.27	0.50

Wykresy:

Porównanie cech irysów dotyczących działki kielicha (Sepal) i płatka (Petal)
w podziale na gatunki (wykresy rozrzutu)

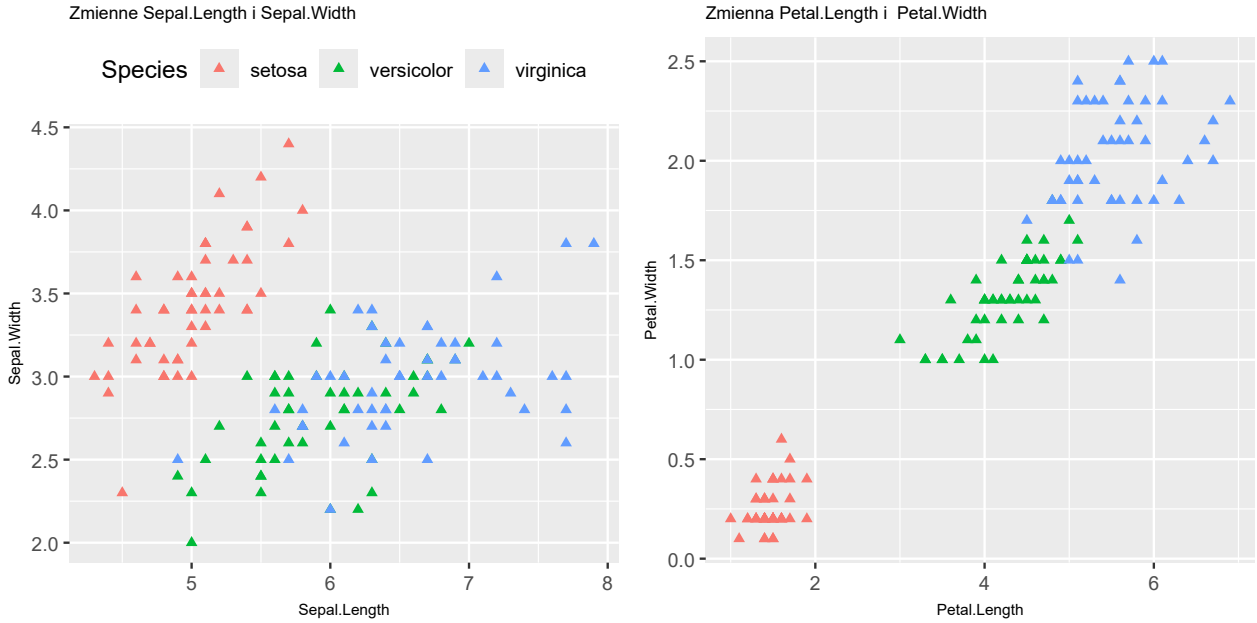

- Na podstawie powyższych wykresów widać, że cechy opisujące rozmiary działki kielicha mają gorsze zdolności dyskryminacyjne niż cechy opisujące rozmiary płatka.

Porównanie cech irysów w podziale na gatunki (wykresy pudełkowo_skrzypcowy)

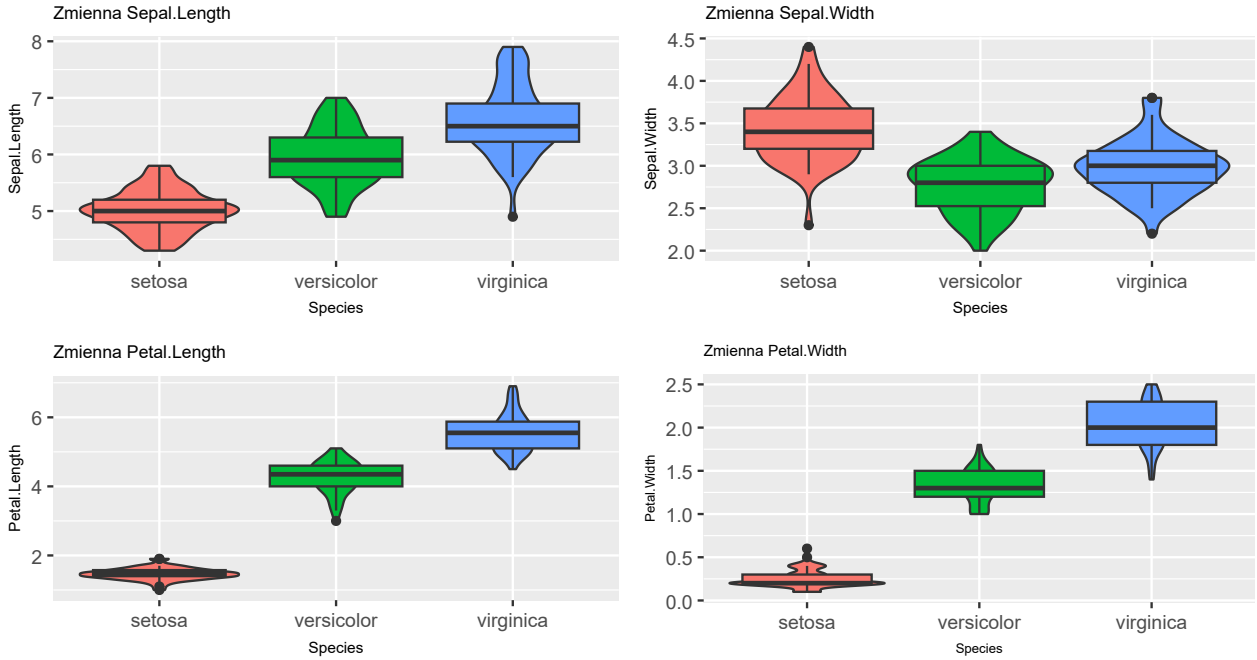

- Na podstawie powyższych wykresów widać, że cechą o najlepszej zdolności dyskryminacyjnej jest `Petal.Length` - opisująca długość płatka, szczególnie oddzielając `setosa` od pozostałych, natomiast cechą o najgorszej zdolności dyskryminacyjnej jest `Sepal.Width`.

1.3 Porównanie nienadzorowanych metod dyskretyzacji

- Aby ocenić, która spośród metod dyskretyzacji: *Equal frequency*, *Equal width* , *K-means clustering*, czy dyskretyzacja na bazie przedziałów zadanych przez użytkownika jest najskuteczniejsza, zostanie przeprowadzona seria wykresów (Histogramy, Wykresy pudełkowe, Wykresy Mozaikowe), dotycząca cech `Petal.Length` i `Sepal.Width`, oraz zostanie utworzona tabelka zawierająca współczynniki zgodności poszczególnych metod dyskretyzacji, porównująca ich skuteczność.

Histogramy:

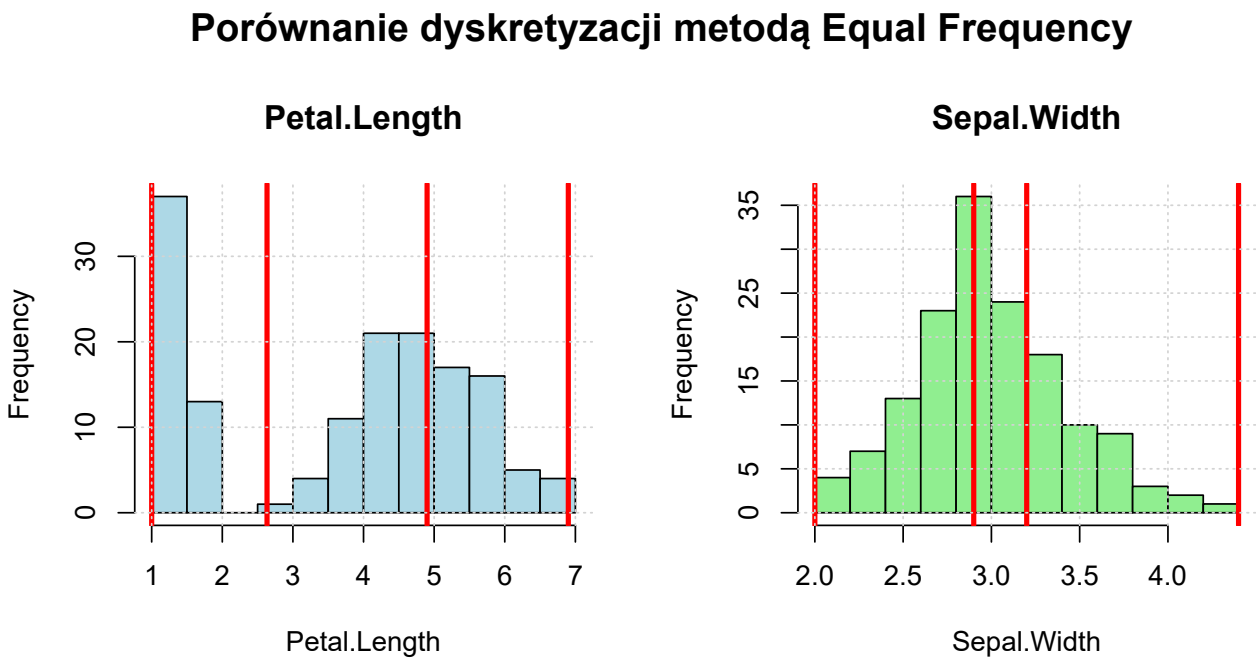

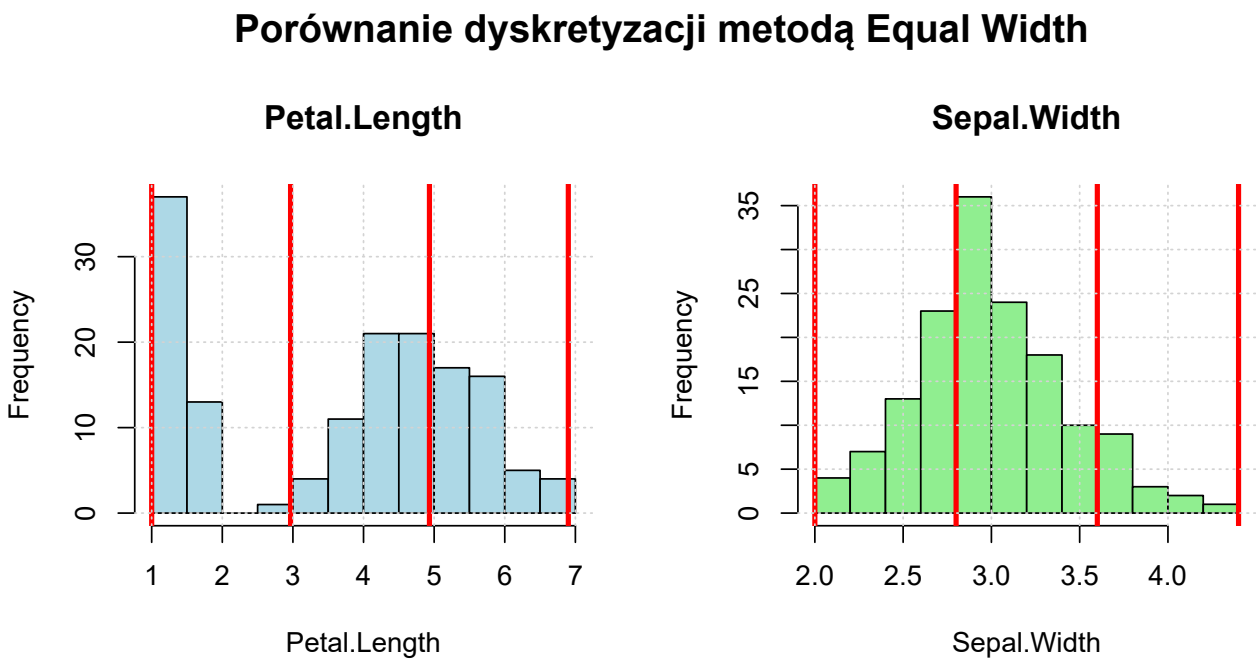

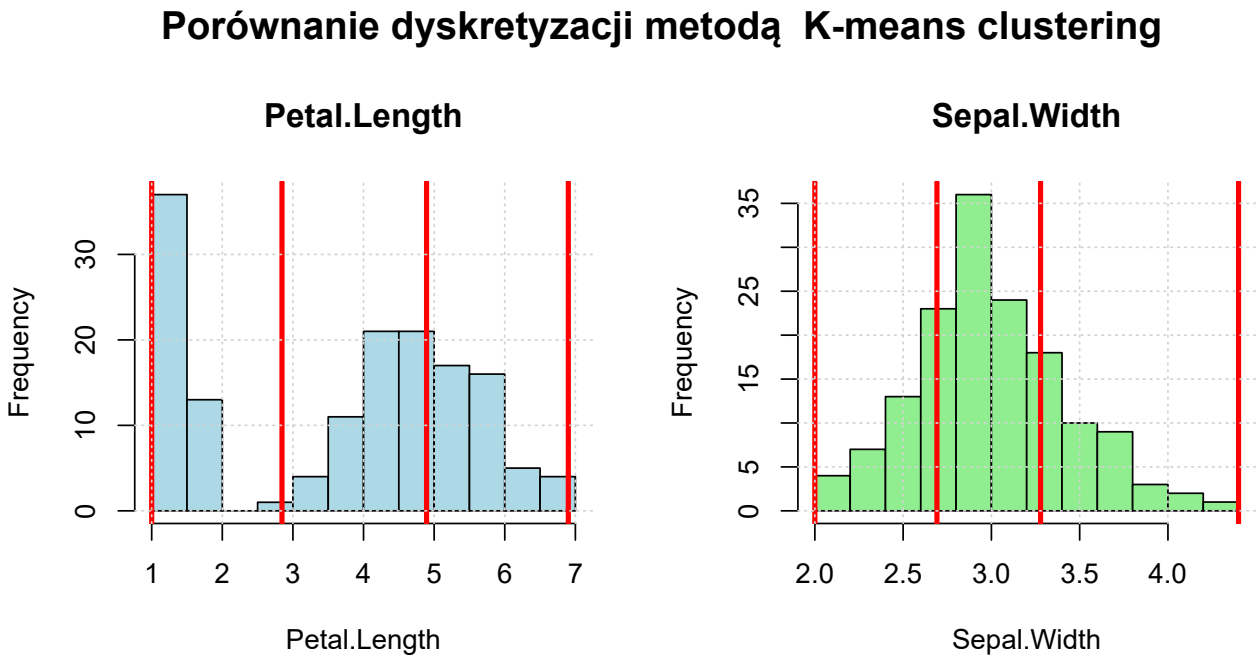

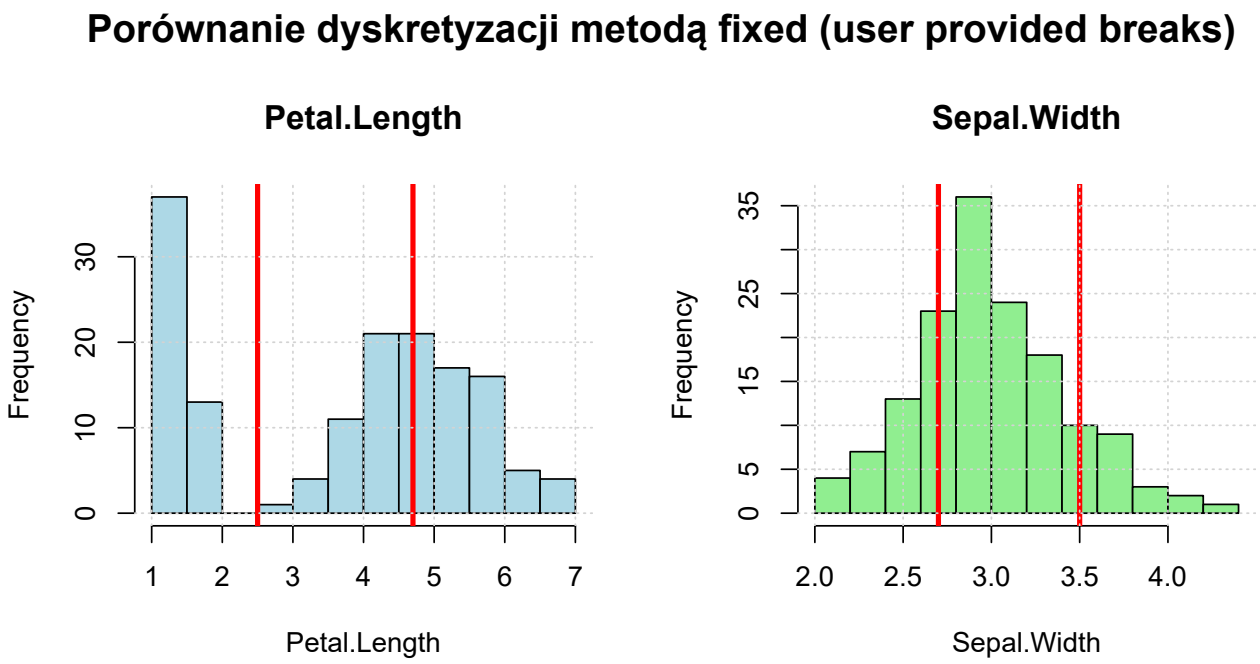

- Powyższe histogramy ilustrują dyskretyzację zmiennych `Petal.Length` i `Sepal.Width`, opartą na:
  - jednakowej częstości
  - jednakowej szerokości przedziałów
  - algorytmie k-means
  - przedziałach zadanych przez użytkownika
- Dane są podzielone na trzy przedziały, a ich granicę wyznaczają czerwone linie.

Wykresy rozrzutu:

Porównanie dyskretyzacji metodą Equal Frequency

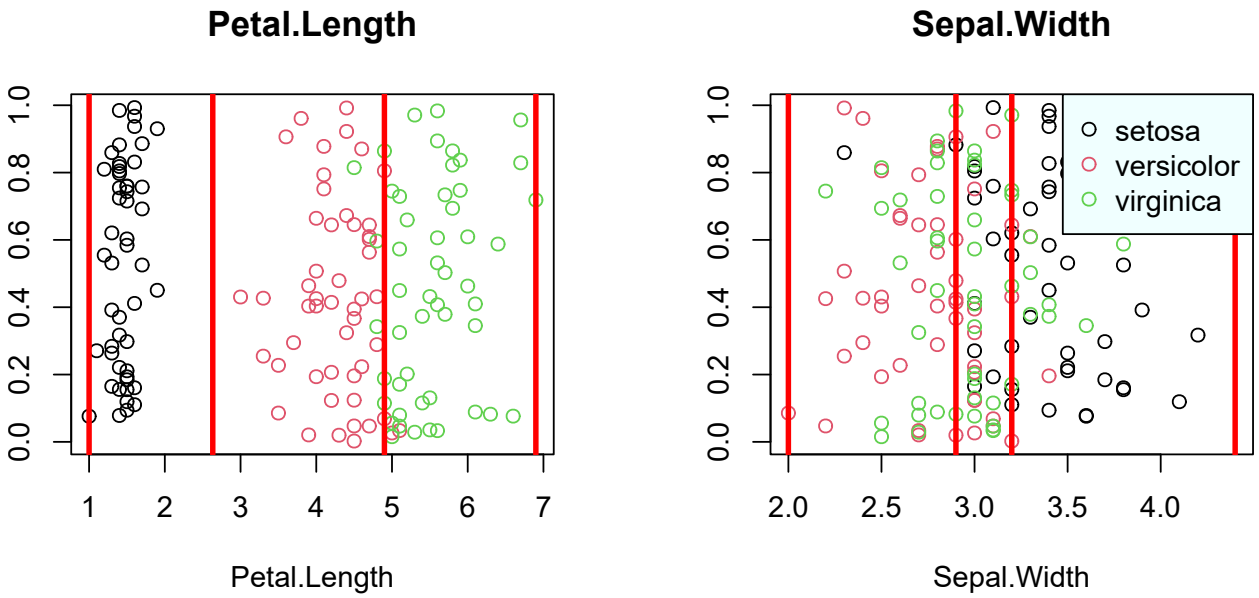

Porównanie dyskretyzacji metodą Equal Width

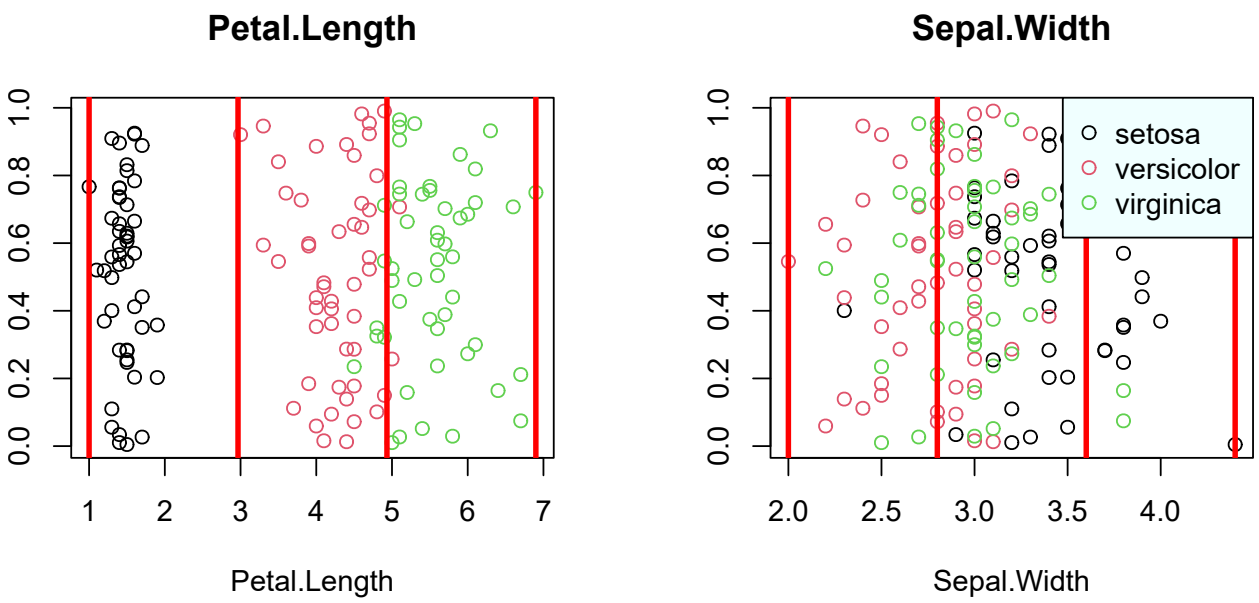

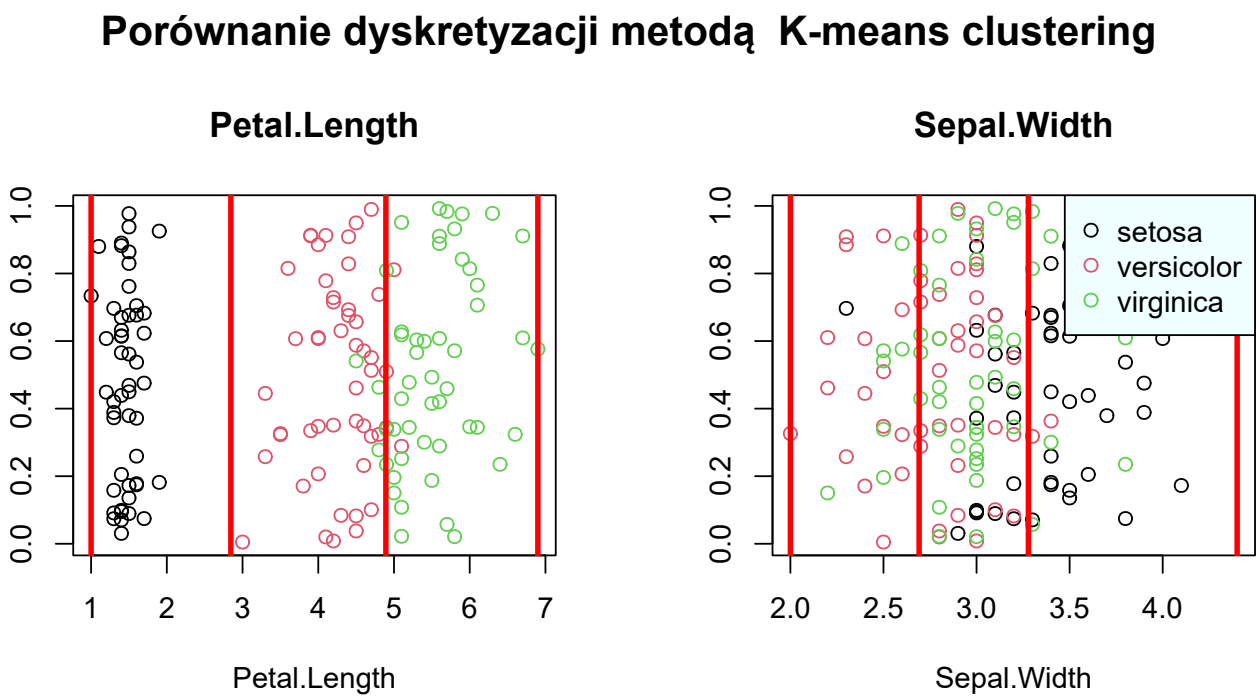

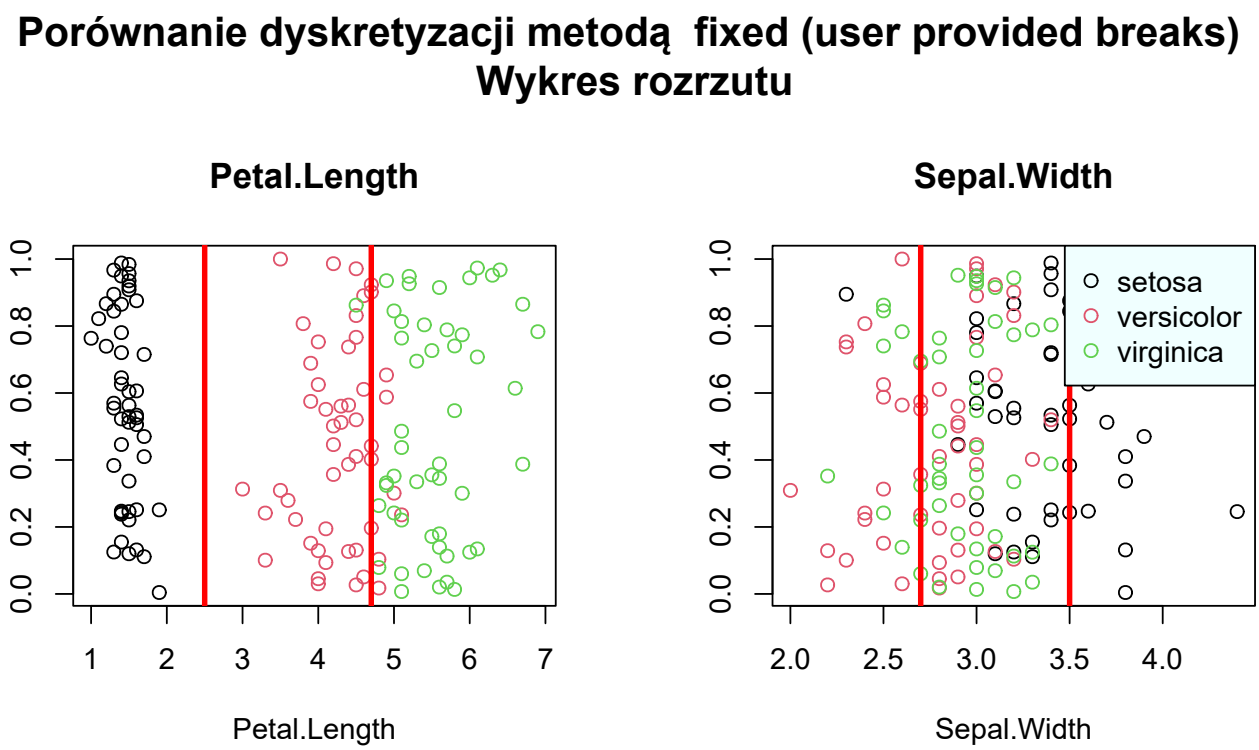

- Powyższe wykresy rozrzutu przedstawiają dyskretyzację zmiennych `Petal.Length` i `Sepal.Width`, opartą na:
  - jednakowej częstości
  - jednakowej szerokości przedziałów
  - algorytmie k-means
  - przedziałach zadanych przez użytkownika
- Pokazują one również porównanie wyznaczonych przedziałów, których granicę wyznaczają czerwone

linie, z rzeczywistym podziałem ze względu na kategorie gatunkowe (`setosa`, `versicolor`, `virginica`).

Wykresy mozaikowe:

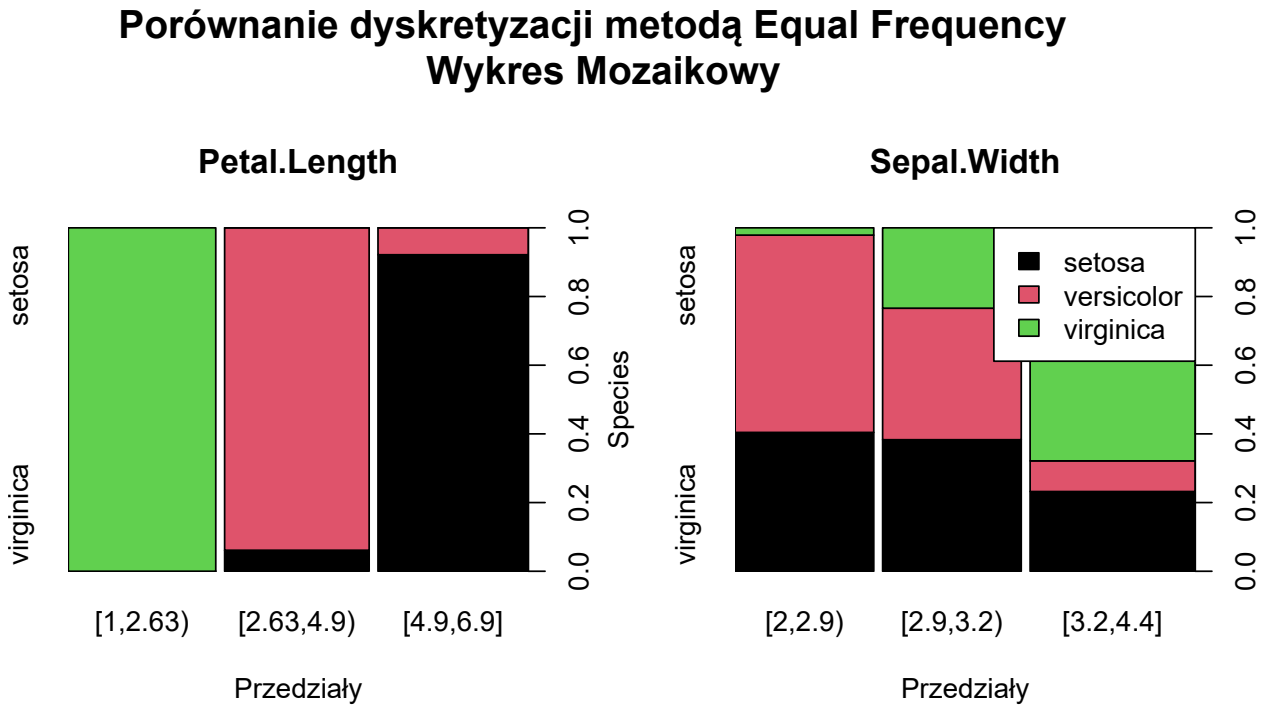

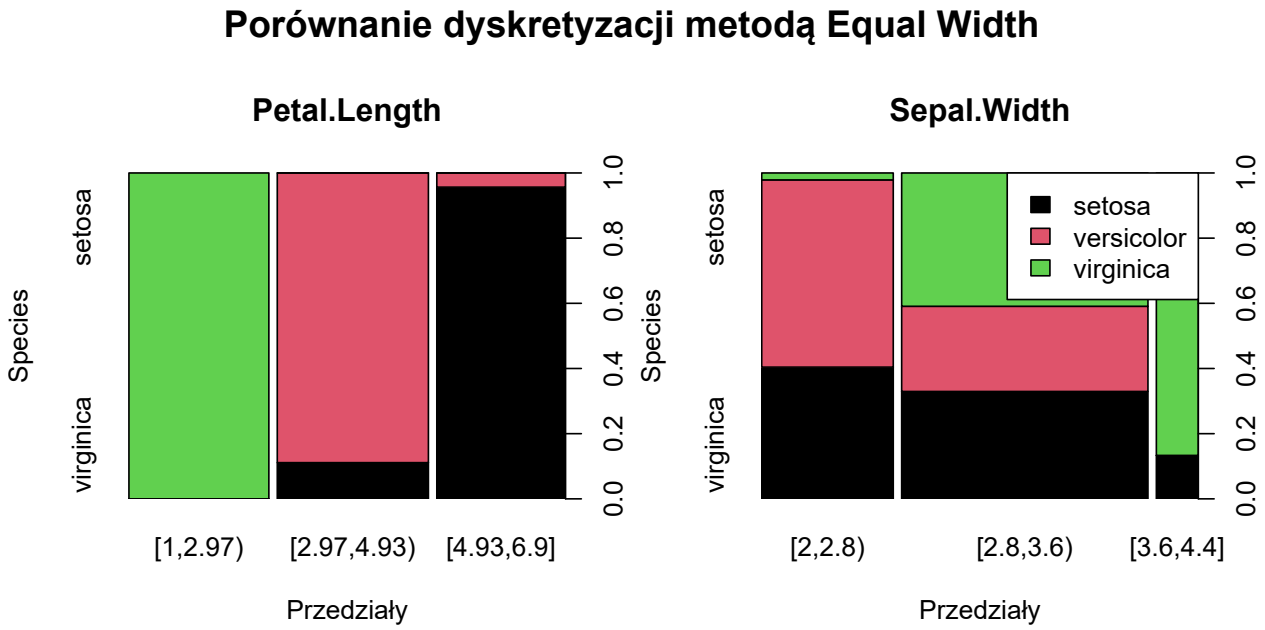

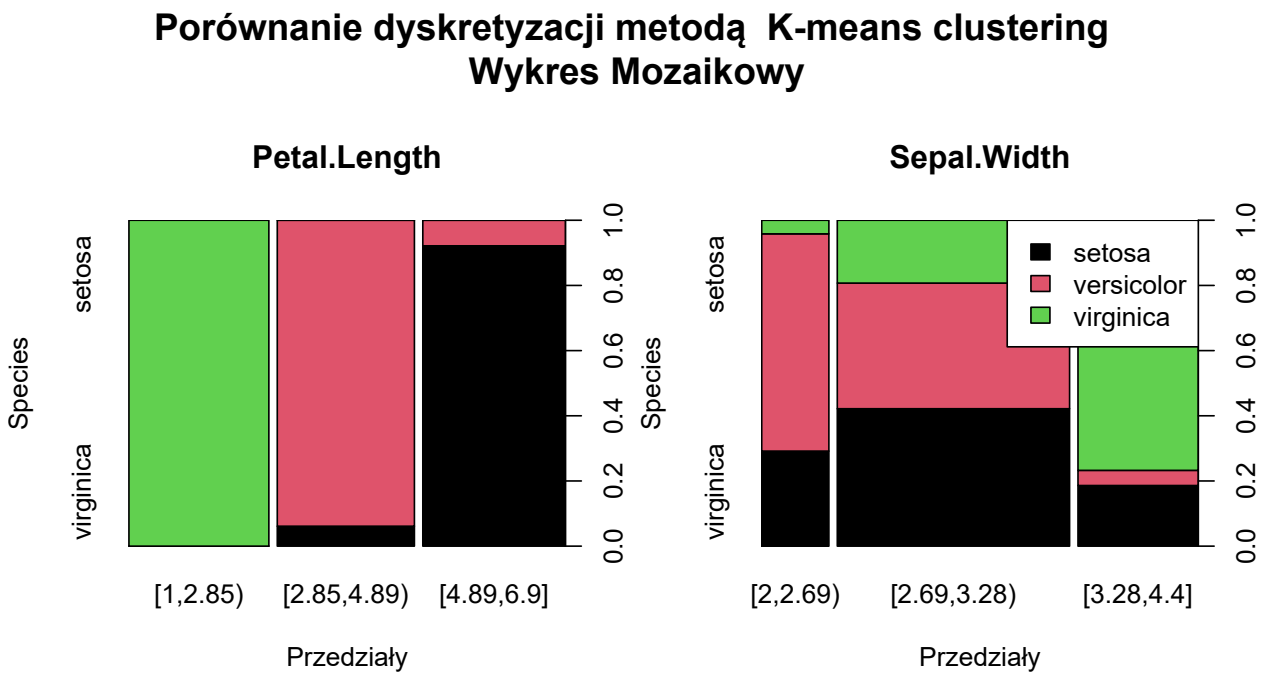

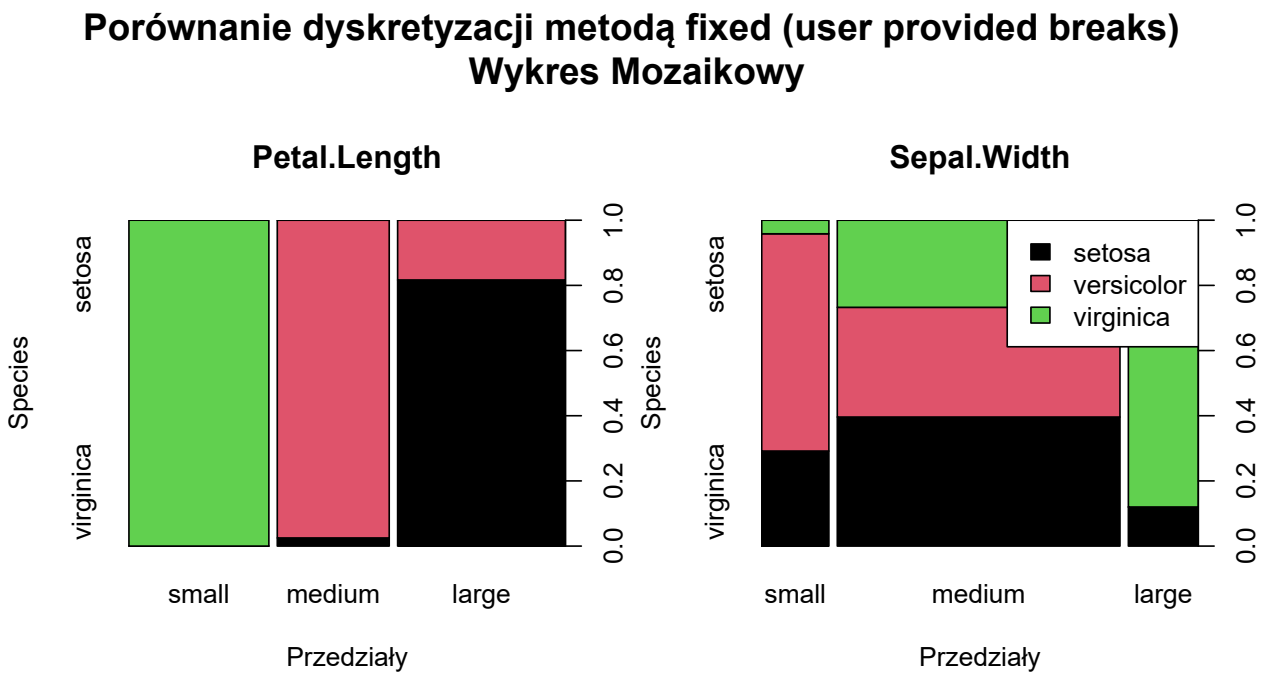

- Powyższe wykresy mozaikowe przedstawiają, w jakim stopniu obiekty należące do poszczególnych przedziałów, są przypisane do różnych kategorii gatunkowych (`setosa`, `versicolor`, `virginica`).

Współczynniki zgodności:

Tabela 4: Tabela zgodności metod dyskretyzacji *Equal frequency, Equal width , K-means clustering, fixed (user provides breaks)* na cechach `Petal.Length` i `Sepal.Width`

	Equal.Frequency	Equal.Width	K.means	Fixed
Petal.Length	0.953	0.947	0.953	0.920
Sepal.Width	0.560	0.413	0.478	0.333

- Na podstawie powyższych wykresów oraz tabeli zawierającej współczynniki zgodności widać, że najskuteczniejszy okazał się algorytm *Equal frequency* .
- Wyniki otrzymane dla cechy o najlepszej zdolności dyskryminacyjnej (`Petal.Length`), zdecydowanie różnią się od wyników otrzymanych dla cechy o najgorszej zdolności dyskryminacyjnej (`Sepal.Width`) - współczynniki zgodności dla `Petal.Length` osiągają prawie dwukrotnie wiekszą wartość (metoda *Equal frequency*) i ponad dwukrotnie wiekszą wartość (metody *Equal width , K-means clustering, fixed (user provides breaks)*) niż współczynniki zgodności dla `Sepal.Width`.

2 Zadanie 2

2.1 Wprowadzenie

Dane: City Quality of Life Dataset (plik uaScoresDataFrame.csv, źródło: Kaggle)

- Zbiór danych zawiera wskaźniki opisujące jakość życia w wybranych miastach, w tym m.in. takie charakterystyki jak: warunki mieszkaniowe, koszty utrzymania, bezpieczeństwo, opieka zdrowotna, edukacja itp.
- Wszystkie cechy ilościowe przyjmują wartości w zakresie `0-10` (większa wartość oznacza lepszy wynik).
- Dodatkowo mamy informację nt. lokalizacji danego miasta (zmienne `UA_Continent` i `UA_Country`).

Typy poszczególnych cech:

```
## 'data.frame':    266 obs. of  21 variables:
##  $ X                   : int  0 1 2 3 4 ...
##  $ UA_Name             : Factor w/ 264 levels "Aarhus","Adelaide",..: 1 2 3 4 5 ...
##  $ UA_Country          : Factor w/ 135 levels " Alabama"," Alaska",..: 28 6 84 59 82 ...
##  $ UA_Continent        : Factor w/ 6 levels "Africa","Asia",..: 3 5 4 2 3 ...
##  $ Housing             : num  6.13 6.31 ...
##  $ Cost.of.Living      : num  4.02 4.69 ...
##  $ Startups            : num  2.83 3.14 ...
##  $ Venture.Capital     : num  2.51 2.64 ...
##  $ Travel.Connectivity  : num  3.54 1.78 ...
##  $ Commute             : num  6.31 5.34 ...
##  $ Business.Freedom    : num  9.94 9.4 ...
##  $ Safety              : num  9.62 7.93 ...
##  $ Healthcare          : num  8.7 7.94 ...
##  $ Education           : num  5.37 5.14 ...
##  $ Environmental.Quality: num  7.63 8.33 ...
##  $ Economy             : num  4.89 6.07 ...
##  $ Taxation            : num  5.07 4.59 ...
##  $ Internet.Access     : num  8.37 4.34 ...
##  $ Leisure...Culture   : num  3.19 4.33 ...
##  $ Tolerance           : num  9.74 7.82 ...
##  $ Outdoors            : num  4.13 5.53 ...
```

Braki danych:

```
##                    X               UA_Name            UA_Country
##                    0                     0                     0
##          UA_Continent               Housing        Cost.of.Living
##                    0                     0                     0
##              Startups       Venture.Capital   Travel.Connectivity
##                    0                     0                     0
##               Commute      Business.Freedom                Safety
##                    0                     0                     0
##            Healthcare             Education Environmental.Quality
```

```
##                    0                    0                    0
##              Economy             Taxation       Internet.Access
##                    0                    0                    0
##    Leisure...Culture            Tolerance              Outdoors
##                    0                    0                    0
```

Nie występują żadne braki danych kodowane jako `NA`. W teorii brakujące dane mogą być kodowane jako `0`, jednak nie jesteśmy w stanie tego zweryfikować.

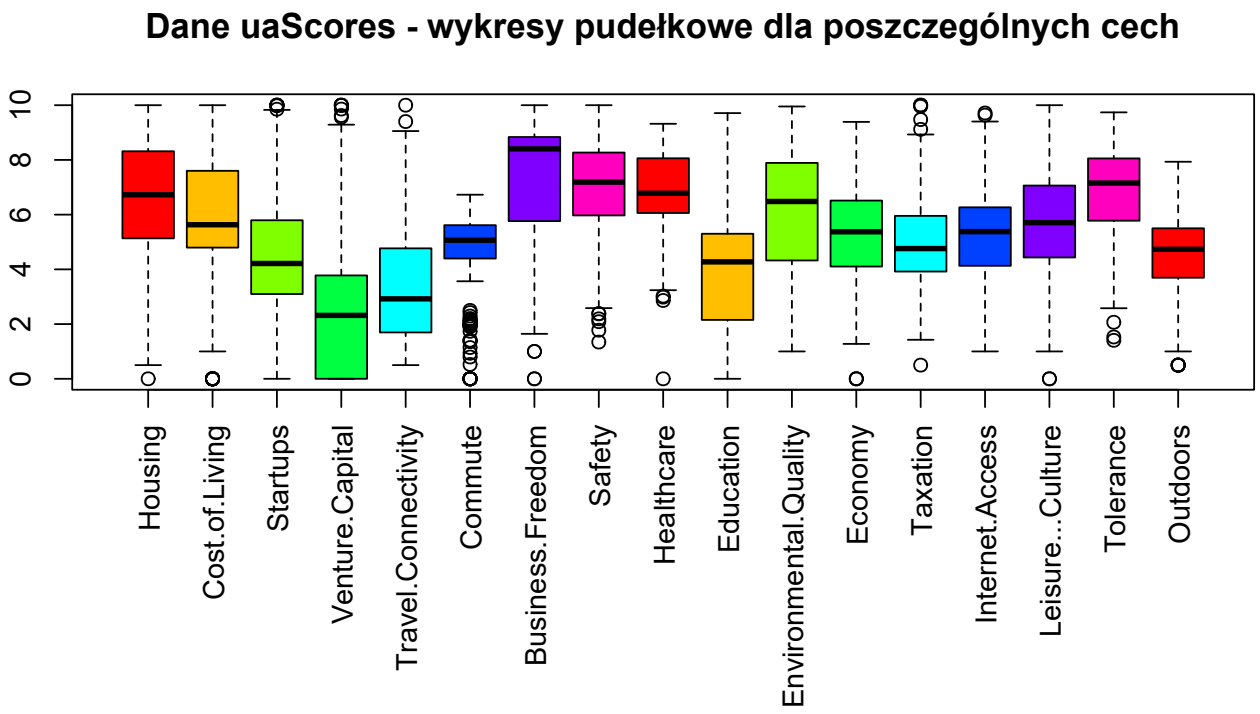

Rysunek 1: Wykresy pudełkowe dla danych uaScores

Porównanie wykresów pudełkowych dla poszczególnych zmiennych (Rys.1) wskazuje na konieczność uwzględnienia standaryzacji danych. W szczególności wyraźnie widoczny jest dużo większy rozrzut (wariancja) w przypadku zmiennej `Venture.Capital`

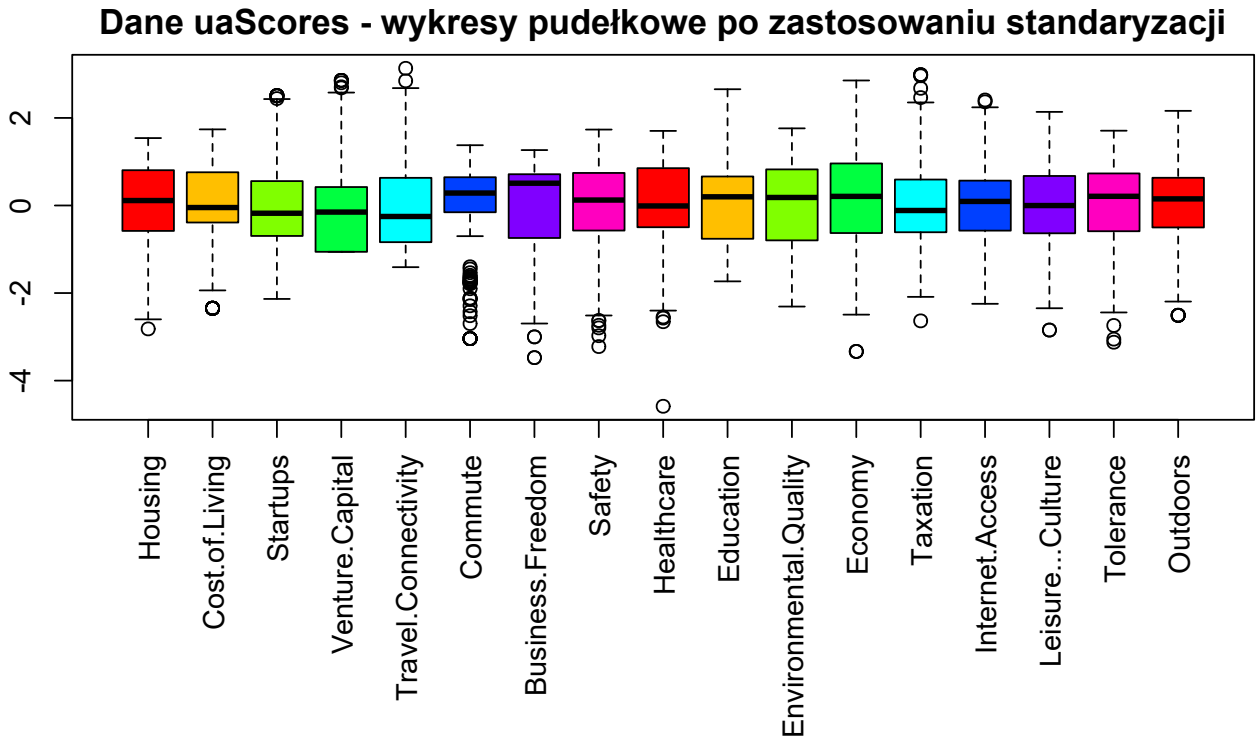

Rysunek 2: Wykresy pudełkowe dla danych uaScores po wykonaniu standaryzacji

2.2 Analiza składowych głównych (PCA)

```
## Standard deviations (1, .., p=17):
##  [1] 2.2507172 1.6054548 1.4429959 1.1402195 1.0945134 0.9800293 0.8311720
##  [8] 0.8146284 0.7638741 0.6514808 0.5685963 0.5392829 0.5241446 0.4342512
## [15] 0.3926602 0.3520450 0.3131903
##
## Rotation (n x k) = (17 x 17):
##                              PC1         PC2          PC3         PC4
## Housing               0.30782507  0.05335338 -0.313546491 -0.37506705
## Cost.of.Living        0.25960906 -0.17578152 -0.330535177 -0.36439019
## Startups             -0.18023854 -0.48344148  0.006099991  0.04783700
## Venture.Capital      -0.23659743 -0.42745094  0.014876825  0.12173181
## Travel.Connectivity  -0.20945432 -0.13530669 -0.339775966  0.15794774
## Commute              -0.11420445  0.02593103 -0.505735874 -0.23037907
## Business.Freedom     -0.37728094  0.09821960  0.024104574 -0.26165230
## Safety               -0.03893545  0.28710395 -0.333009986  0.44064270
## Healthcare           -0.28035896  0.24194822 -0.281024808 -0.09708503
## Education            -0.40256205 -0.04907952 -0.073864482 -0.06579104
## Environmental.Quality -0.32622202  0.25253554  0.053571655 -0.10257542
## Economy              -0.27317525 -0.07400327  0.308670514 -0.26650822
## Taxation              0.02629917  0.10741513 -0.020184933  0.13277592
## Internet.Access      -0.27619221  0.02270564  0.028441569 -0.28565205
## Leisure...Culture    -0.07444660 -0.36473241 -0.305054520  0.03125997
## Tolerance            -0.18974955  0.35509112 -0.102725071  0.17189005
## Outdoors             -0.09158656 -0.19338254 -0.148586789  0.37912443
##                               PC5          PC6         PC7          PC8
## Housing              -0.002889644  0.100358416  0.04277032 -0.070663045
```

```
## Cost.of.Living        -0.171039019  0.122398298  0.10594857 -0.176627052
## Startups              -0.186802129 -0.001658894  0.21797615 -0.123982958
## Venture.Capital       -0.096308679 -0.108920896  0.15966504 -0.298763466
## Travel.Connectivity    0.203181850 -0.485558890 -0.22215907 -0.054585190
## Commute               -0.188615568  0.047646278 -0.11241330 -0.272735844
## Business.Freedom      -0.065234105  0.121197528 -0.21449203  0.112063302
## Safety                -0.231740955 -0.241385668  0.15916731 -0.194819407
## Healthcare             0.176275769 -0.031292943 -0.27068557  0.182170411
## Education              0.023247869 -0.048369764 -0.07933731  0.052225349
## Environmental.Quality  0.017332148  0.244790022  0.11232203 -0.154104568
## Economy               -0.275659184  0.018648123 -0.26238733 -0.141173469
## Taxation              -0.819919610 -0.036952880 -0.10263657  0.356641718
## Internet.Access       -0.007388950 -0.133989769  0.59008053  0.085397138
## Leisure...Culture      0.098601223  0.159057917  0.13502868  0.699026021
## Tolerance              0.024211637  0.283587338  0.44432176 -0.003748053
## Outdoors               0.034866661  0.680777558 -0.21258953 -0.169032371
##                              PC9        PC10         PC11        PC12
## Housing                0.05064861 -0.34778940 -0.035178916 -0.04836668
## Cost.of.Living        -0.01776758 -0.31089515  0.085068090  0.04125663
## Startups              -0.26474953 -0.14447963 -0.033466703 -0.04474152
## Venture.Capital       -0.17299394 -0.08440600 -0.264196824 -0.24983165
## Travel.Connectivity    0.19301868 -0.04582724  0.428232937 -0.02377228
## Commute               -0.10403888  0.70682025 -0.002409499  0.04325942
## Business.Freedom      -0.02612294 -0.15651563  0.025096734 -0.01960004
## Safety                 0.09088651 -0.30843748 -0.104565679  0.41831742
## Healthcare            -0.14724233 -0.29945761 -0.179788902 -0.40348692
## Education             -0.02825441 -0.04314902 -0.271027062  0.02731912
## Environmental.Quality  0.09994091 -0.01366572 -0.372760724  0.38595837
## Economy               -0.04505886 -0.17346220  0.479960611  0.34776484
## Taxation               0.10647276  0.02806771 -0.039839810 -0.25737398
## Internet.Access        0.60547716  0.06384382  0.116223300 -0.19666154
## Leisure...Culture     -0.08568874  0.04057603  0.019410840  0.40300820
## Tolerance             -0.47002170 -0.01247935  0.468169136 -0.17759501
## Outdoors               0.44651724 -0.06770240  0.126119590 -0.14630714
##                             PC13         PC14        PC15        PC16
## Housing               -0.03688525  0.007641252 -0.11718933 -0.43603029
## Cost.of.Living        -0.08241646  0.260301119  0.03025353  0.37786588
## Startups              -0.27154564 -0.526266297 -0.13272331  0.30772312
## Venture.Capital        0.15765473  0.286017176  0.26783376 -0.48650717
## Travel.Connectivity   -0.45686077  0.173271108  0.02278124 -0.05285686
## Commute                0.12939365 -0.142418748  0.03470610 -0.02485675
## Business.Freedom      -0.14783744 -0.313960314 -0.42648425 -0.40332415
## Safety                 0.29217202 -0.211851918 -0.07970066 -0.04232607
## Healthcare             0.19479881 -0.203104195  0.43575569  0.24307658
## Education              0.21438393  0.490662083 -0.55376032  0.29190957
## Environmental.Quality -0.53888156  0.139293056  0.32439750  0.01630383
## Economy                0.31126615  0.053941043  0.26268928  0.01268909
## Taxation              -0.20981683  0.157521391  0.05913654 -0.01388589
## Internet.Access        0.16592899 -0.109890920  0.05189487  0.04620018
## Leisure...Culture      0.09585719  0.032756834  0.15753675 -0.13483258
## Tolerance             -0.05828095  0.192688365 -0.05995269 -0.04489094
## Outdoors               0.07240356 -0.016155608 -0.02571380  0.02433321
##                              PC17
## Housing                0.560476070
```

```
## Cost.of.Living        -0.498853841
## Startups               0.276765080
## Venture.Capital       -0.161318543
## Travel.Connectivity    0.051758165
## Commute                0.037811566
## Business.Freedom      -0.458562938
## Safety                -0.089593937
## Healthcare             0.036087376
## Education              0.241691927
## Environmental.Quality  0.080259114
## Economy                0.189991964
## Taxation               0.076768137
## Internet.Access       -0.001589184
## Leisure...Culture     -0.021451129
## Tolerance              0.037808167
## Outdoors               0.043953792
```

- Jak widzimy, wynik (w postaci listy) zawiera m.in. informację nt. odchyleń standardowych poszczególnych składowych głównych (ang. standard deviations) oraz wyznaczoną macierz ładunków (ang. loadings), która została nazwana rotation.

```
##              PC1         PC2         PC3         PC4        PC5        PC6
## [1,] -2.23779653  2.74382582 -0.89443501 -0.15884235 -0.2212988 -0.2783877
## [2,] -1.25135654  1.45298000  0.08235983 -0.06595051 -0.1043034  1.1249621
## [3,] -0.03723886 -0.05871921  1.70828684 -2.65111877  0.4938802  1.1452471
## [4,]  2.75772927  0.59029462 -0.84077299  0.09802470 -2.1795551  0.1386040
## [5,] -3.26134700 -1.29152075 -1.71941437  1.71673442  0.1240275 -0.6032357
## [6,] -0.52832788  1.18528663  2.19711688 -0.93302756  0.3510045  1.5416312
##             PC7        PC8        PC9       PC10        PC11         PC12
## [1,]  0.9048947 -0.7004344  0.3358268  0.1604426  0.08416409 -0.704856044
## [2,] -0.7297677 -0.6978479 -0.2807941 -0.2012702 -0.43755144  0.270485677
## [3,] -0.4992780  0.2549999 -0.5581084  0.9832141  0.34200297 -0.573147572
## [4,] -1.1977778 -0.8916870  0.6234745  0.3296537  1.24812841 -0.241741051
## [5,] -0.1470426  0.2341621 -0.9252560  0.3391196  0.30267652  0.437526518
## [6,] -0.9775520 -0.3166628  0.3921613  1.1597802  0.25888026 -0.005873786
##            PC13        PC14        PC15        PC16       PC17
## [1,]  0.6708248 -0.34643814 -0.34961627 -0.32304558 -0.2704496
## [2,]  0.5048883  0.01970388 -0.06778667 -0.26923971 -0.1003650
## [3,] -0.5805755  0.58617982  0.03637074 -0.01962053  0.2719990
## [4,] -0.6137899  1.02716147 -0.59852891  0.04126427  0.2143755
## [5,] -0.8101052 -0.08147574  0.13682431 -0.04186513 -0.1098348
## [6,] -0.8216768  0.22304443  0.05026872 -0.02540202  0.3722776
```

- Ponieważ zaznaczyliśmy opcję retx=TRUE, wynikowa lista zawiera również macierz state.pca$x, która stanowi nową reprezentacją danych w przestrzeni PC1, PC2, ..., PC17.

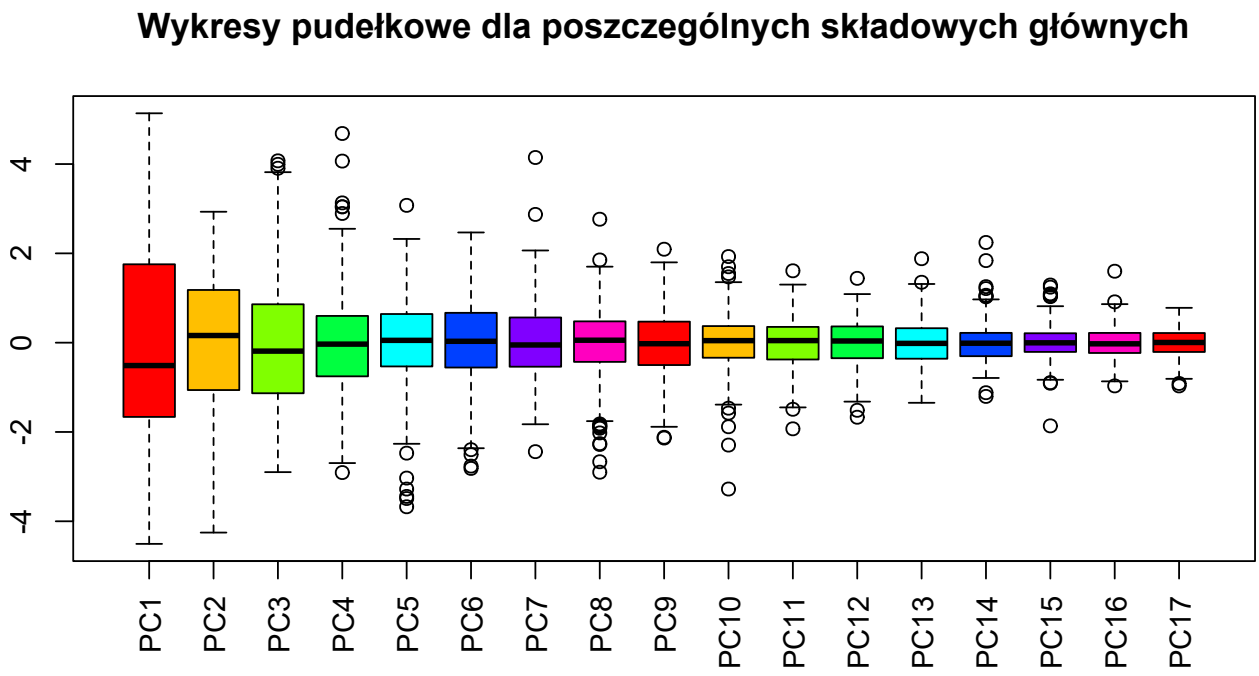

Rysunek 3: Wykresy pudełkowe dla poszczególnych składowych głównych

- Na podstawie wykresów pudełkowych można zauważyć, że największy rozrzut ma składowa główna PC1, co potwierdza jej dominującą rolę w wyjaśnianiu zmienności danych. Wraz z kolejnymi składowymi (PC2–PC17) zakres rozrzutu systematycznie maleje

Wkład zmiennych do kolejnych składowych (PC1, PC2 i PC3)

- **Uwaga**: przerywana, czerwona linia oznacza oczekiwany średni wkład pojedynczej zmiennej:

$$= \frac{1}{\text{liczba zmiennych}} \cdot 100\%, \quad \text{czyli w naszym przypadku } \frac{1}{17} \cdot 100\% \approx 5{,}88\%$$

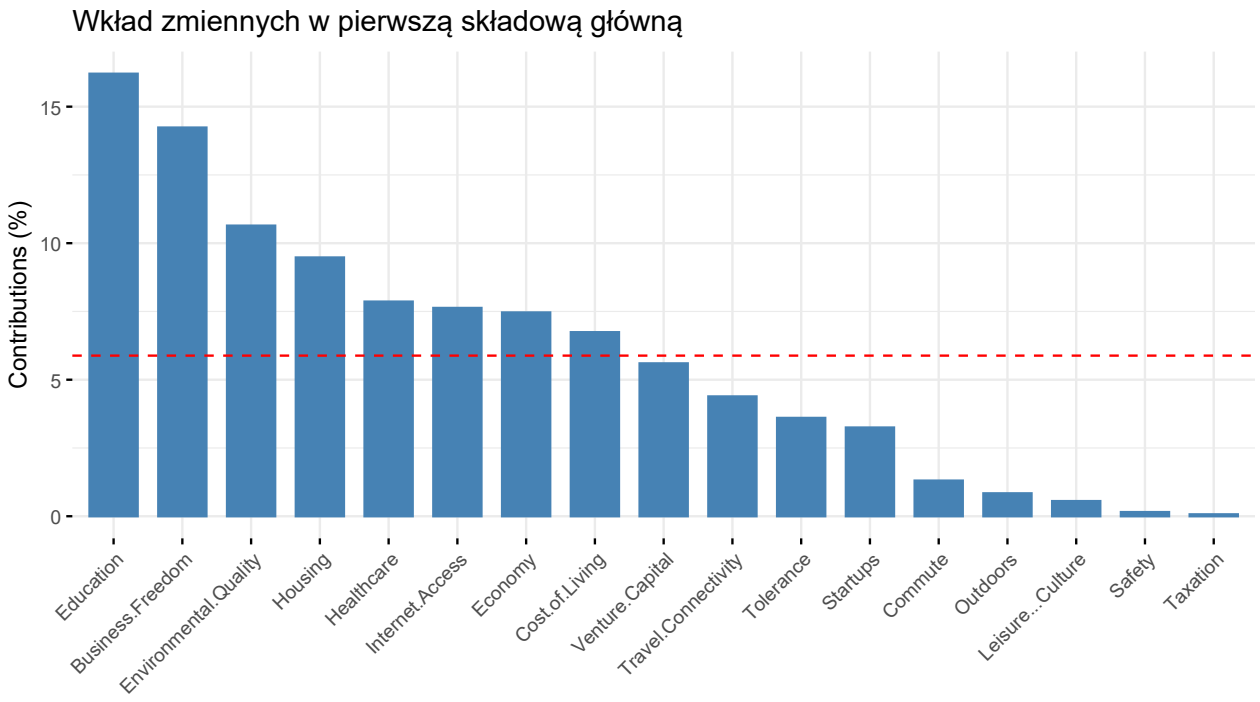

Rysunek 4: Wkład poszczególnych zmiennych do PC1

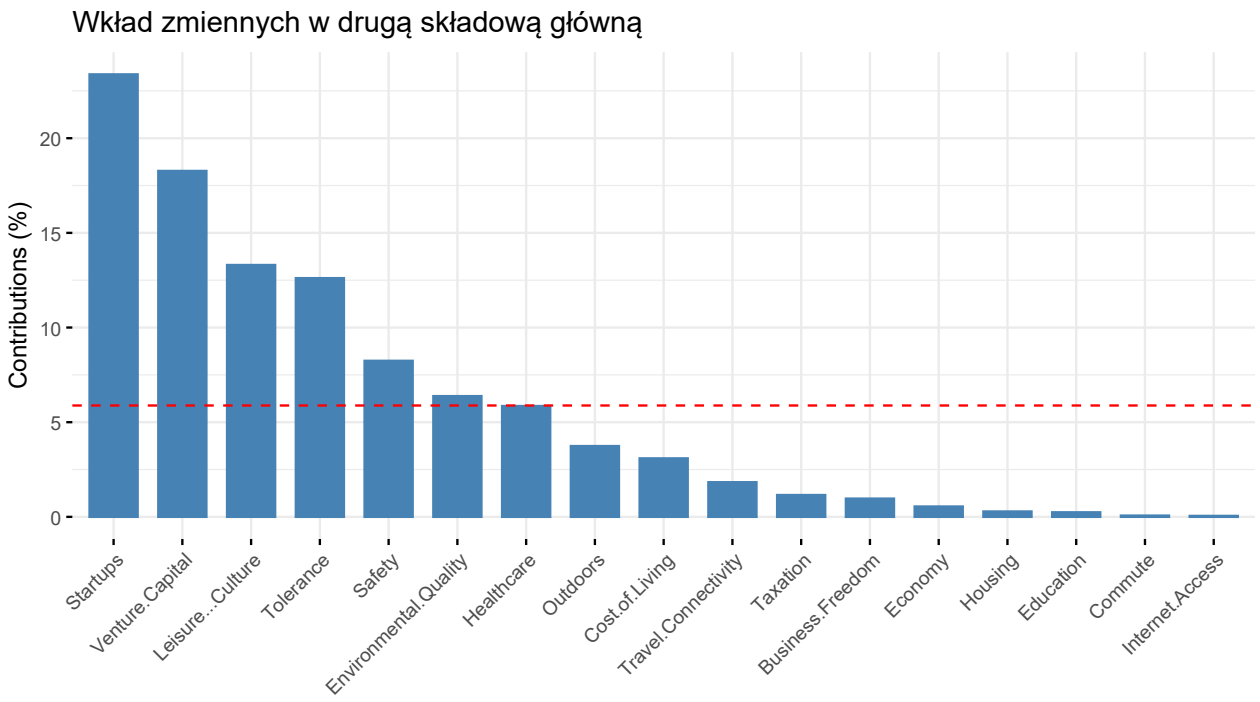

Rysunek 5: Wkład poszczególnych zmiennych do PC2

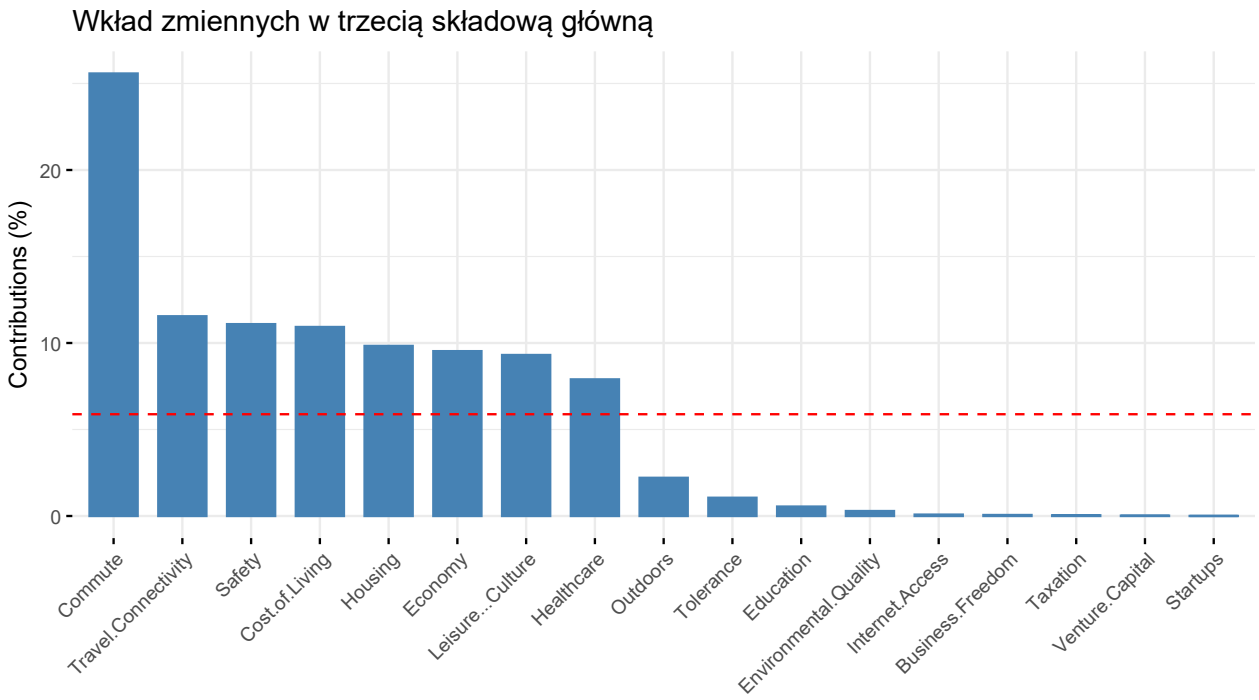

Rysunek 6: Wkład poszczególnych zmiennych do PC3

Interpretacja:

- PC1: Wysokie wartości dla zmiennych takich jak Housing (warunki mieszkaniowe) oraz Cost of Living (koszty życia) sugerują, że pierwsza składowa głównie odnosi się do kosztów życia w mieście.
- PC2 : Wysokie wartości dla zmiennych takich jak Safety (bezpieczeństwo), Healthcare (opieka zdrowotna) i Tolerance (tolerancja) wskazują na to, że ta składowa skupia się na jakości życia pod względem bezpieczeństwa, zdrowia i otwartości społecznej.
- PC3: Zmienne takie jak Economy (gospodarka) i Startups (start-upy) mają większy wpływ na tę składową. Miasta z silną gospodarką i dużymi możliwościami dla nowych firm będą miały wyższą wartość tej składowej.

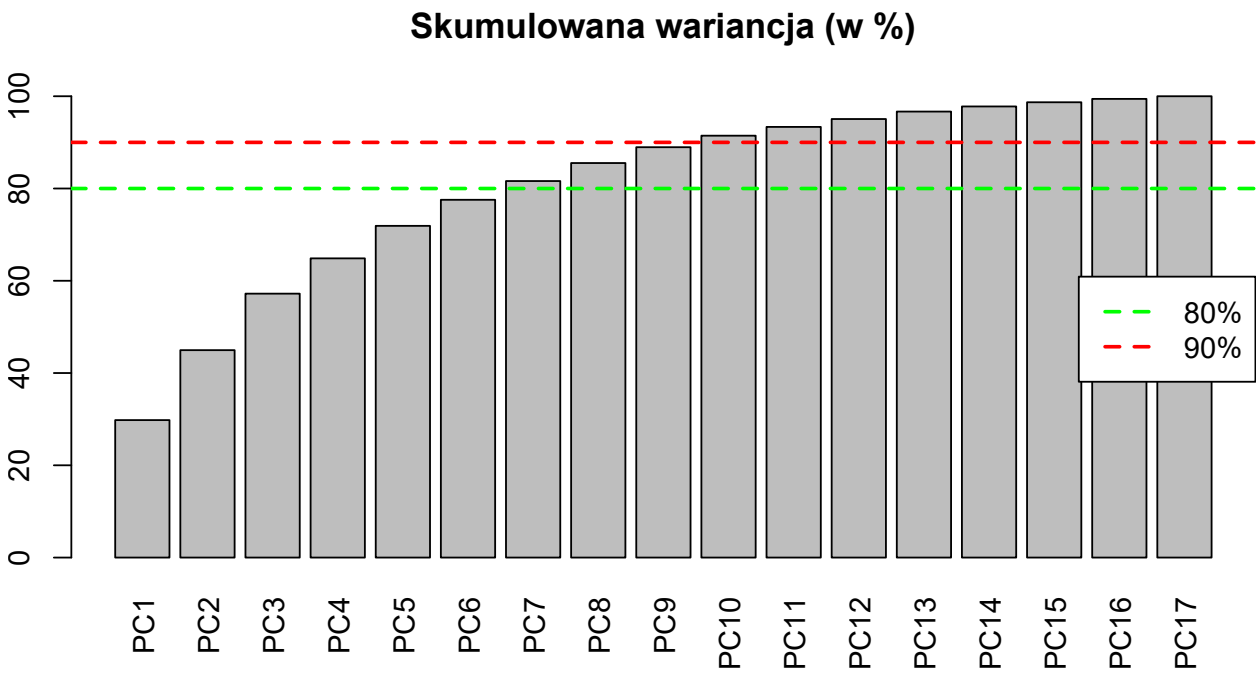

Rysunek 7: Skumulowana wariancja (w %)

- **Wnioski**: Widzimy, że ograniczając się do trzech pierwszych składowych (PC1, PC2 i PC3) zachowujemy około 60% całkowitej zmienności danych. Z kolei, potrzebujemy 7 oraz 9 pierwszych składowych (tj. PC1, PC2,..., PC7, PC8, PC9), aby wyjaśnić kolejno około 80% i 90% całkowitej zmienności danych.

2.3 Wizualizacja danych wielowymiarowych

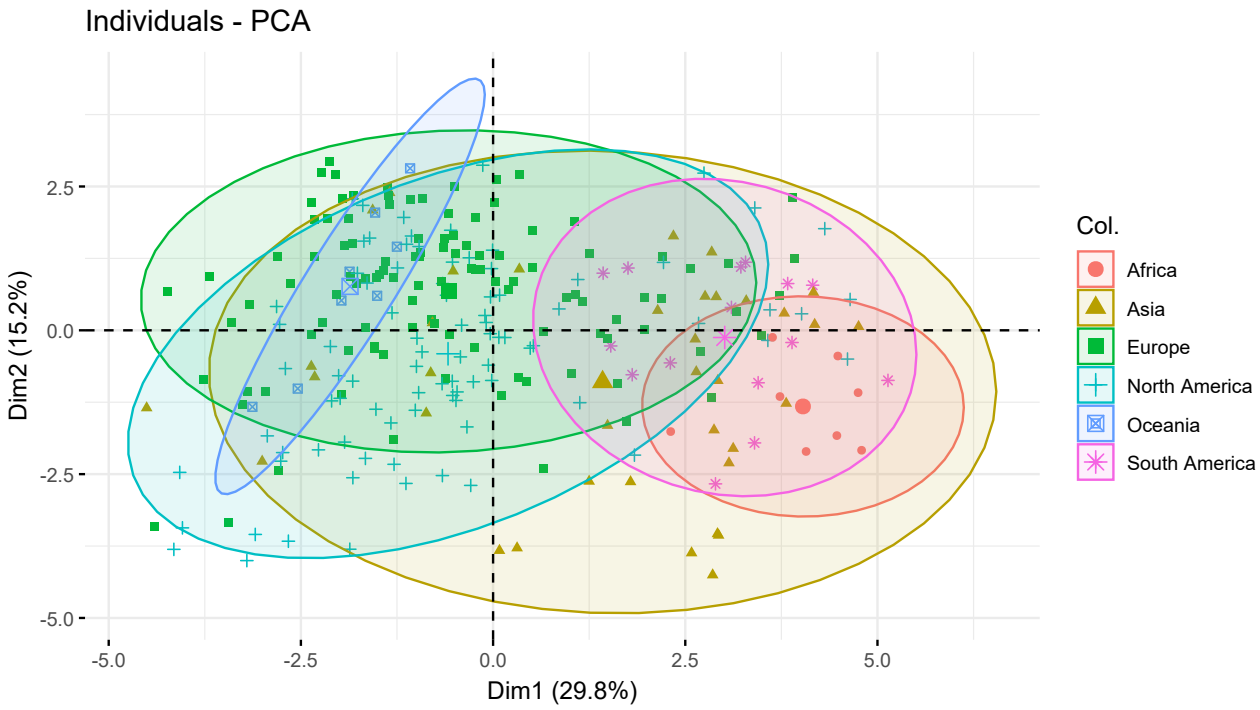

Rysunek 8: Wykres rozrzutu w przestrzeni (PC1,PC2) wraz z informacją nt. przynależności do grup (zmienna `UA_Continent`) oraz dodanymi elipsami koncentracji (na poziomie ufności 90%)

Analiza wykresu 2D:

- **Europa** — dominuje w centralnej części wykresu, co wskazuje na zrównoważony poziom jakości życia i bezpieczeństwa. Miasta europejskie są relatywnie podobne między sobą.
- **Ameryka Północna** i **Oceania** — skupione bardziej po lewej stronie PC1, co sugeruje wysoki poziom edukacji, zdrowia i środowiska przy wyższych kosztach życia. Elipsa otaczająca miasta Oceanii jest wąska, co wskazuje na niewielkie zróżnicowanie — miasta są do siebie podobne pod względem analizowanych cech.
- **Azja** — bardziej rozproszona, ale wiele miast ma umiarkowane lub wysokie wartości PC1 i niskie PC2, co może sugerować niższy poziom bezpieczeństwa lub tolerancji, ale dobrą gospodarkę i rozwój infrastruktury.
- **Afryka** — skupiona w dolnej prawej części wykresu (PC1 wysoki, PC2 niski), co może oznaczać niższy poziom edukacji, zdrowia oraz większe problemy z bezpieczeństwem.
- **Ameryka Południowa** — grupuje się wokół wartości dodatnich PC1 i umiarkowanych PC2, czyli przeciętny koszt życia, ale gorsze wyniki w zakresie bezpieczeństwa i jakości usług.

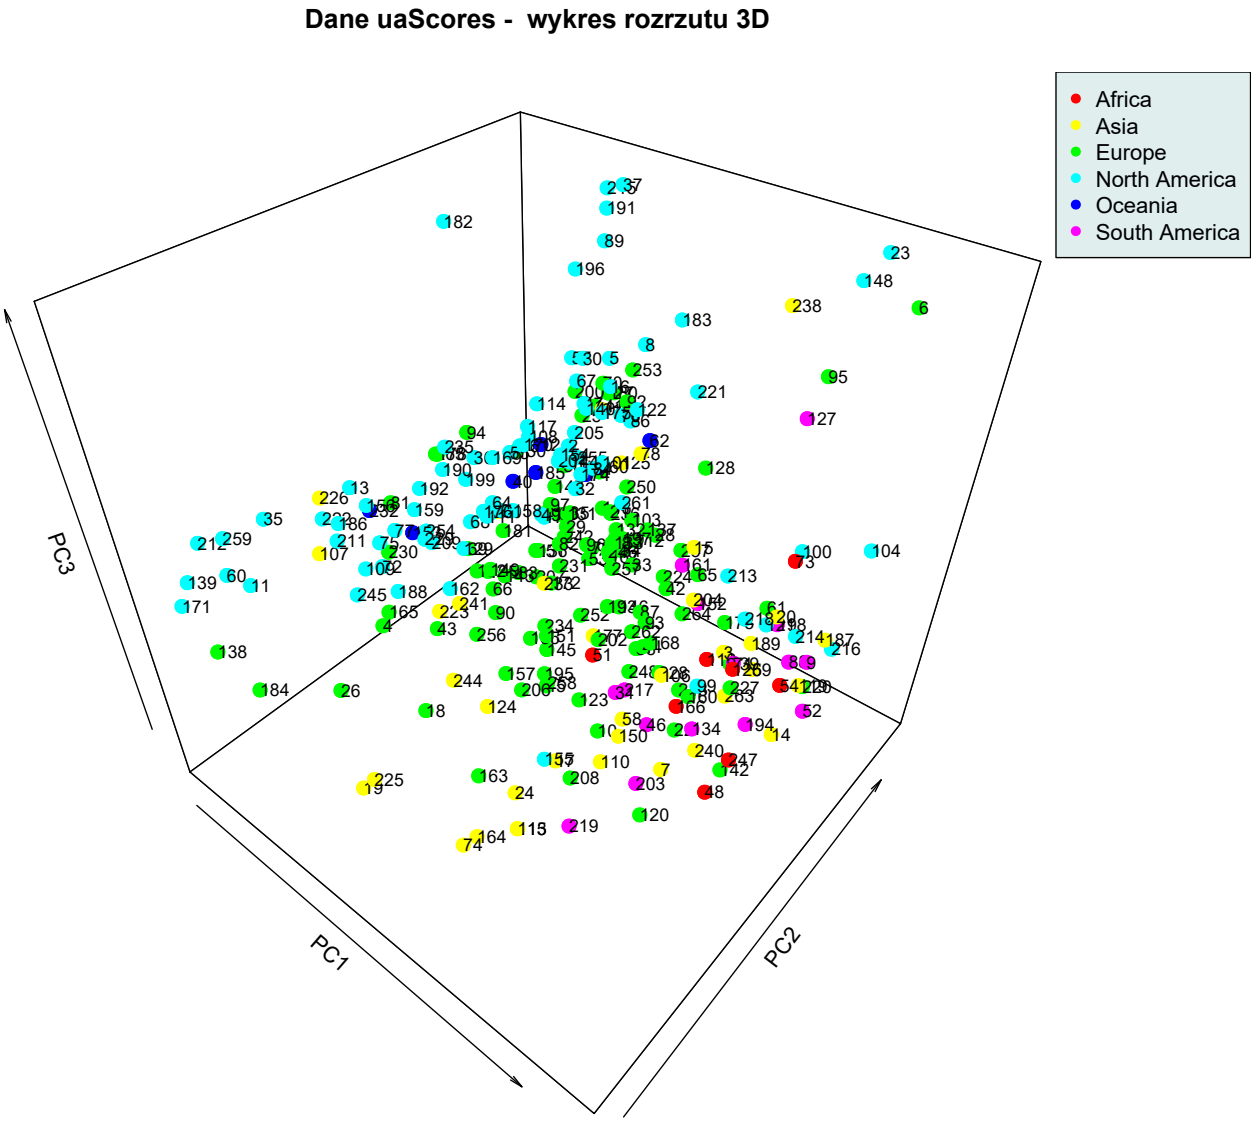

Rysunek 9: Wykres rozrzutu w przestrzeni (PC1,PC2,PC3)

Analiza wykresu 3D:

- **Ameryka Północna** jest zróżnicowana – niektóre miasta znajdują się w obszarze wysokich wartości PC1, niskich PC2 i PC3, co oznacza niższą jakość usług społecznych i bezpieczeństwa, ale również bardziej przystępne koszty życia. Inne miasta mogą mieć wyższe wartości PC3, co sugeruje dynamiczną gospodarkę lub lepsze skomunikowanie. Ogólnie, miasta północnoamerykańskie wykazują mieszany profil, często zróżnicowany pomiędzy dużymi, kosztownymi metropoliami a mniejszymi, tańszymi miastami.
- **Ameryka Południowa** znajduje się zazwyczaj na obrzeżach wykresu, z wysokimi wartościami PC1 i niskimi PC2 i PC3. Sugeruje to niższą jakość edukacji, zdrowia, wolności gospodarczej i środowiska, przy jednocześnie niższych kosztach życia. Niskie wartości PC2 i PC3 wskazują natomiast na gorsze bezpieczeństwo, mniejszą tolerancję oraz słabszą infrastrukturę transportową i gospodarczą.
- **Afryka** również prezentuje silnie zróżnicowane rozmieszczenie miast, często na obrzeżach wykresu PCA. Miasta afrykańskie zazwyczaj mają dodatnie wartości PC1, co oznacza niską jakość usług i niższy koszt życia, oraz niskie wartości PC2, wskazujące na mniejszą tolerancję i niższy poziom bezpieczeństwa. Wartości PC3 są zmienne – niektóre miasta wykazują potencjał gospodarczy, inne relatywnie lepszą infrastrukturę transportową. Ogólnie jednak, kontynent ten cechuje się niższym poziomem rozwoju miejskiego i jakości życia.
- **Azja**, podobnie jak Ameryka Północna, jest kontynentem kontrastów. Część miast azjatyckich zbliżona jest profilem do miast europejskich – wyróżniają się one niskimi PC1 oraz dodatnimi PC2 i PC3, co wskazuje na wysoką jakość życia, bezpieczeństwo i dynamiczną gospodarkę. Inne miasta azjatyckie, znajdujące się na przeciwnych krańcach wykresu, mają wysokie koszty życia, niższe bezpieczeństwo i mniejszą tolerancję. W rezultacie, Azja to kontynent, gdzie obok wysoko rozwiniętych metropolii występują również miasta o znacznie niższym standardzie życia.
- **Oceania** wyróżnia się jako kontynent o wyjątkowo jednolitym i pozytywnym profilu. Miasta tego regionu skupione są w obszarze niskich wartości PC1, wysokich PC2 i umiarkowanych PC3, co oznacza bardzo wysoką jakość edukacji, zdrowia, środowiska i wolności gospodarczej, a także wyjątkowe bezpieczeństwo i tolerancję. Jedynym istotnym minusem są wysokie koszty życia. Oceania prezentuje się więc jako region o najwyższym standardzie życia, z bardzo zbliżonymi parametrami pomiędzy miastami.

Analiza wizualna wykresu pozwala również zidentyfikować przykładowe miasta najbardziej odbiegające od reszty:

```r
print(as.character(dane$UA_Name[dane$X == 23]))
```

```
## [1] "Belize City"
```

```r
print(as.character(dane$UA_Name[dane$X == 6]))
```

```
## [1] "Andorra"
```

- **Belize City** (Belize, Ameryka Północna) wyróżnia się bardzo niską jakością życia – praktycznie nie ma rozwiniętej sieci transportu ani infrastruktury biznesowej, a usługi publiczne (zdrowie, edukacja) są ograniczone. Przy bardzo niskich kosztach życia miasto cechuje się także słabym stanem środowiska i umiarkowanym poziomem bezpieczeństwa.
- **Andorra** (Andorra, Europa) wyróżnia się spośród europejskich miast skrajnie niskim poziomem usług publicznych i infrastruktury biznesowej – praktycznie nie rozwija się tu rynek startupów, transport jest minimalny, a system zdrowia i edukacji ograniczony. Jednocześnie cechuje się jednym z najwyższych poziomów bezpieczeństwa i tolerancji oraz bardzo czystym środowiskiem i dobrym dostępem do internetu. Ta nietypowa kombinacja – niski rozwój gospodarczy przy dobrych warunkach życia – czyni z Andorry, wyraźnie odbiegającą od normy, obserwacje odstającą na tle Europy. (Podejrzewam jednak, że Andorra wypadła odstająco przez braki w danych (kodowane jako `0`))

2.4 Korelacja zmiennych

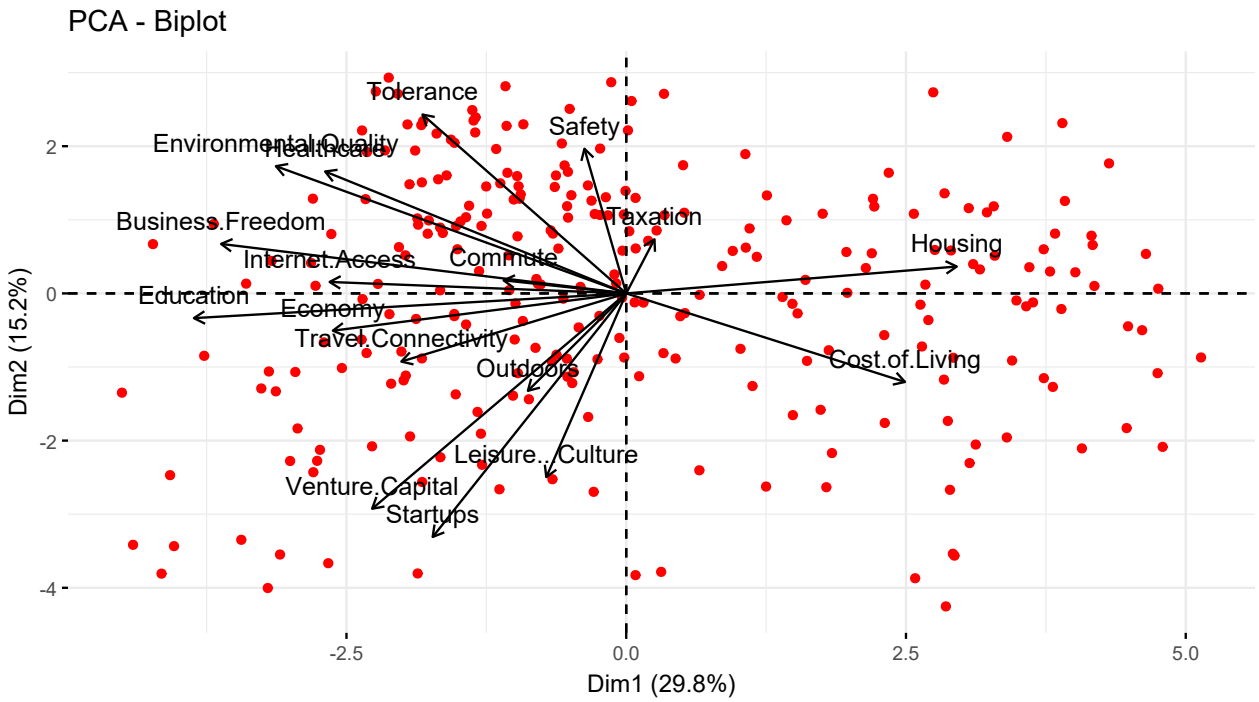

Rysunek 10: Dwuwykres (ang. biplot) dla domyślnych parametrów, z usuniętymi nazwami obserwacji

Analiza dwuwykresu dla wybranych zmiennych:

- **Housing**

Wektor `Housing` jest jednym z najdalej wysuniętych w prawo na osi PC1, niemal równoległy do `Cost.of.Living`. Oznacza to bardzo silną dodatnią korelację między tymi dwiema miarami — miasta z wysokim standardem mieszkań są też zdecydowanie droższe w utrzymaniu. Natomiast `Housing` jest niemal przeciwstawiony wektorom `Education`, `Business.Freedom`, `Healthcare` i `Environmental.Quality`, co oznacza silne ujemne współzależności.

- **Education**

Wektor `Education` wychodzi wyraźnie w lewo wzdłuż osi PC1, wskazując na dodatnie korelacje z innymi lewostronnymi zmiennymi: przede wszystkim z `Business.Freedom`, ale też z `Internet.Access` czy `Economy`. Oś PC2 jest dla `Education` niemal neutralna. `Education` jest zatem częścią tego lewostronnego klastra obejmującego środowisko przyjazne biznesowi i technologicznie zaawansowane miasta, a przeciwstawiona jest kosztowności mieszkaniowej.

- **Business.Freedom**

`Business.Freedom` ląduje na lewo od środka, nieco ponad osią poziomą, co sygnalizuje dodatnie korelacje z `Education` i umiarkowane z `Healthcare` oraz `Environmental.Quality` (wszystkie te wektory są skierowane w podobnym północno-zachodnim kierunku). Z kolei `Business.Freedom` jest odwrotnie skierowana do `Housing` i `Cost.of.Living` oraz niemalże prostopadle do `Startups` i `Venture.Capital`, co odzwierciedla ujemny związek między swobodą prowadzenia działalności a wysokimi kosztami życia.

- **Travel.Connectivity**

`Travel.Connectivity` występuje lekko na lewo i lekko w dół, co oznacza umiarkowane dodatnie sprzężenie z `Education`, `Internet.Access`, `Commute` i częściowo ze `Startups` oraz `Venture.Capital`. Jednocześnie jest ujemnie skorelowana z `Housing`, `Cost.of.Living`, co sugeruje, że dobre transportowe powiązania raczej nie towarzyszą najwyższym kosztom mieszkania.

- **Outdoors**

Wektor `Outdoors` jest praktycznie przy środku i bardzo krótki, co odzwierciedla niemal zerowe korelacje ze wszystkimi analizowanymi zmiennymi. Jeśli już, to nieco z `Startups`, `Venture.Capital` czy `Leisure…Culture` (wektory nieznacznie skierowane ku południowo-zachodniej ćwiartce), jednak te związki są marginalne (słabsze niż dla pozostałych cech). Innymi słowy dostęp do terenów zielonych w badanych miastach jest względnie niezależny od zarówno ekonomiczno-mieszkaniowych.

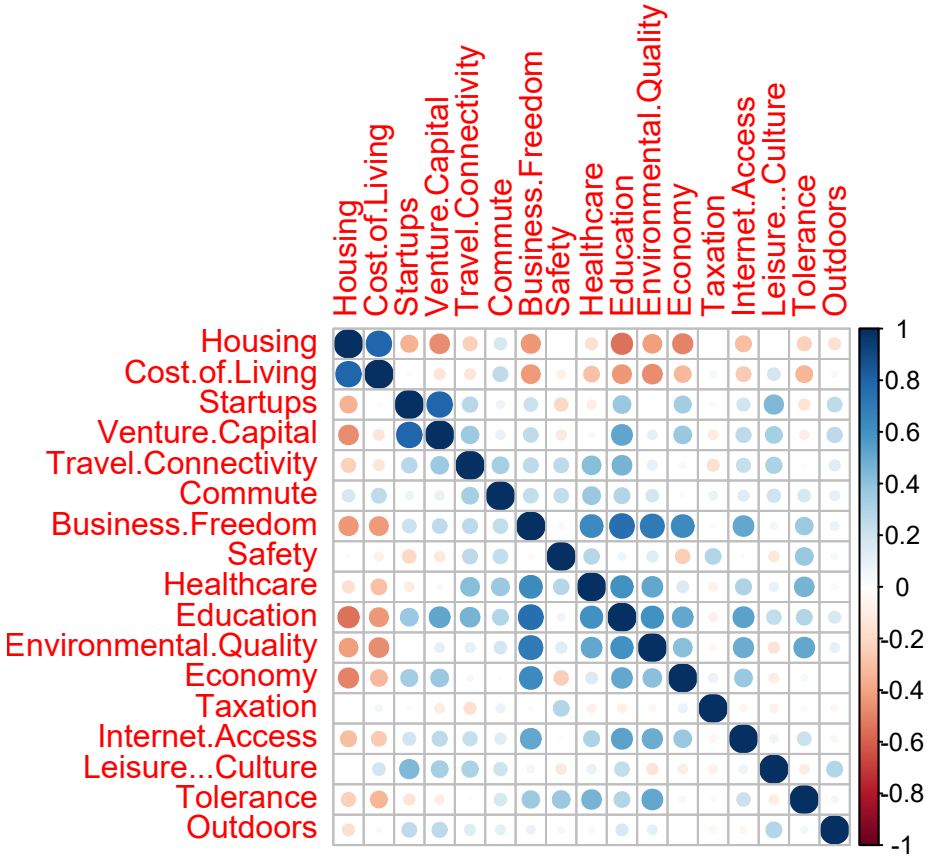

Rysunek 11: Korelacja oryginalnych zmiennych

Analiza macierzy korelacji dla wybranych zmiennych:

- **Housing**

Najsilniej dodatnio koreluje z `Cost.of.Living` – miasta z lepszym standardem mieszkań są też droższe w utrzymaniu. Wykazuje umiarkowaną ujemną korelację z `Education` i z `Economy`.

- **Education**

Silnie dodatnio skorelowana z `Business.Freedom` oraz z `Venture.Capital` – ośrodki akademickie o wysokim poziomie kształcenia wspierają rozwój przedsiębiorczości i przyciągają kapitał inwestycyjny. Ponadto umiarkowana korelacja z `Internet.Access` podkreśla rolę infrastruktury cyfrowej w instytucjach naukowych.

- **Business.Freedom**

Wykazuje silne dodatnie korelacje z `Education`, `Environmental.Quality`, `Healthcare` i `Economy` – swobodny rynek sprzyja rozwojowi edukacji, ochronie środowiska, służbie zdrowia i ogólnej kondycji gospodarki.

- **Travel.Connectivity**

Umiarkowanie dodatnio skorelowana z `Education` oraz `Healthcare` – dobra sieć transportowa ułatwia mobilność studentów i pacjentów, co może wpływać na poziom usług edukacyjnych i medycznych. Dodatnie powiązania z `Venture.Capital` i `Commute` sugerują, że rozwinięte połączenia komunikacyjne sprzyjają zarówno inwestycjom w kapitał ryzyka.

- **Outdoors**

Najwyższa dodatnia korelacja z `Leisure...Culture` oraz z `Venture.Capital` i `Startups`, co może oznaczać, że miasta z rozwiniętą ofertą outdoorową jednocześnie przyciągają inwestorów i aktywne społeczności startupowe.

Wniosek: Obie metody dają zbliżone wyniki i się uzupełniają. Biplot pozwala szybko, *na oko* zobaczyć, które zmienne razem *idą w parze*, a macierz korelacji podaje dokładne wartości mówiące, jak silne są te związki. Razem dają pełniejszy pogląd na korelacje zmiennych.

2.5 Końcowe wnioski

Ciekawe obserwacje:

- Miary mieszkaniowo-ekonomiczne (`Housing`, `Cost.of.Living`) tworzą wyraźny klaster dodatnio skorelowanych zmiennych, odwrotnie zaś niż z grupą związanych z jakością życia (`Education`, `Healthcare`, `Environmental.Quality`, `Business.Freedom`).
- Analiza 2D (PC1, PC2) wraz z elipsami pokazała, że Oceania jest wyjątkowo spójna i wysoka we wszystkich wymiarach jakości życia, co wyróżnia ją spośród pozostałych kontynentów.
- Zmienne takie jak `Outdoors` czy `Commute` wykazują niskie korelacje z pozostałymi zmiennymi i na biplocie mają krótkie wektory. Oznacza to, że w różnicowaniu profilu miast stanowią one unikalny, niezależny aspekt

Liczba składowych potrzebnych do odwzorowania danych:

- Pierwsze trzy główne komponenty (PC1–PC3) wyjaśniają około 60 % całej wariancji, co daje podstawowy, ale wciąż niedostateczny obraz struktury danych.
- Aby osiągnąć próg ~80 %, potrzebne jest siedem pierwszych komponentów, a do ~90 % – dziewięć komponentów.

Znaczenie standaryzacji:

- Bez standaryzacji zmienna Venture.Capital (oraz inne o dużej wariancji) zdominowałaby analizę PCA, co mogłoby zataić istotne relacje między pozostałymi cechami.
- Przeskalowanie do średniej 0 i odchylenia 1 wyrównało wkłady wszystkich miar, dzięki czemu PCA i korelacje oddały rzeczywiste struktury zależności, a biplot stał się bardziej czytelny.